

胸部 CT 图像多器官分割实验报告

医学图像处理技术课程项目

摘要

中文摘要

胸部 CT 图像分割是医学影像分析领域的重要研究方向，在肺部疾病诊断、心脏功能评估和气道疾病分析中具有重要应用价值。本研究旨在开发一种基于深度学习的胸部 CT 图像多器官分割方法，实现对肺、心脏和气管三个关键器官的精确分割。

本研究采用 Swin-UNETR v2 深度学习架构，结合 DiceFocalLoss 损失函数和余弦退火学习率调度策略，在胸部 CT 数据集上进行训练。实验结果表明，该方法在测试集上取得了优异的分割性能：肺的 Dice 系数达到 0.9664，心脏为 0.8995，气管为 0.9455，平均 Dice 系数为 0.9371。

研究结果表明，基于 Swin-UNETR 的胸部 CT 多器官分割方法能够有效处理医学图像中的复杂结构，为临床诊断和治疗提供可靠的辅助工具。

Abstract

Chest CT image segmentation is a crucial research direction in medical image analysis, with significant applications in lung disease diagnosis, cardiac function assessment, and airway disease analysis. This study aims to develop a deep learning-based multi-organ segmentation method for chest CT images, achieving precise segmentation of three critical organs: lung, heart, and trachea.

This study employs the Swin-UNETR v2 deep learning architecture, combined with DiceFocalLoss and cosine annealing learning rate scheduling. Experimental results demonstrate that the proposed method achieves excellent segmentation performance on the test dataset: Dice coefficient of 0.9664 for lung, 0.8995 for heart, and 0.9455 for trachea, with an average Dice coefficient of 0.9371.

The results indicate that the Swin-UNETR-based multi-organ segmentation method can effectively handle complex structures in medical images, providing reliable auxiliary tools for clinical diagnosis and treatment.

1 项目背景

1.1 研究意义与应用价值

胸部 CT 是临床诊断中最常用的影像学检查手段之一，能够清晰显示肺部、心脏、气管等重要器官的解剖结构。精确的器官分割是后续计算机辅助诊断（CAD）系统的基础，具有以下重要应用价值：

- **肺部疾病诊断**：辅助检测肺结节、肺气肿、肺炎等疾病
- **心脏功能评估**：测量心脏体积、心室壁厚度等参数
- **气道分析**：评估气管狭窄、支气管扩张等病变
- **手术规划**：为肺部手术提供精确的解剖参考

1.2 研究现状

近年来，深度学习技术在医学影像分割领域取得了显著进展：

- U-Net 系列模型成为医学图像分割的主流方法
- Transformer 架构（如 Swin Transformer）在医学影像领域逐渐兴起
- Swin-UNETR 结合了 U-Net 的局部特征提取能力和 Transformer 的全局建模能力

1.3 存在问题

尽管取得了一定进展，胸部 CT 多器官分割仍面临以下挑战：

- 器官形态变化大，个体差异显著
- 小器官（如气管）的分割难度较大
- 类别不平衡问题（背景像素远多于目标器官）
- 图像质量受扫描设备和参数影响

2 项目方法

2.1 算法原理

本研究采用 Swin-UNETR v2 架构，其核心思想是将 Swin Transformer 作为编码器，结合 U-Net 的解码器结构，实现高效的医学图像分割。

2.1.1 Swin Transformer 编码器

Swin Transformer 通过局部窗口自注意力机制和层级特征提取，有效捕获图像的多尺度特征。其关键操作包括：

- **窗口划分**：将特征图划分为不重叠的局部窗口

- **窗口注意力**：在每个窗口内计算自注意力
- **窗口移位**：通过移位操作实现跨窗口信息交互
- **层级合并**：逐步合并特征图，扩大感受野

2.1.2 U-Net 解码器

解码器采用上采样和跳跃连接结构，将编码器提取的高级特征与低级特征融合，实现精确的分割边界定位。

2.2 网络架构




图 1: Swin-UNETR 网络架构示意图

网络的主要参数配置如下：

表 1: 网络参数配置

参数	数值
输入通道数	1（单通道灰度图）
输出通道数	3（肺、心脏、气管）
基础特征维度	48
空间维度	2D
使用梯度检查点	是
使用 Swin-UNETR v2	是

2.3 数据预处理流程

数据预处理采用 MONAI 框架的变换组合，主要包括以下步骤：

1. **图像加载**：使用 LoadImaged 加载 CT 图像和掩码
2. **通道扩展**：使用 EnsureChannelFirstd 添加通道维度
3. **数据增强**：
 - RandFlipd：随机水平/垂直翻转（概率 0.5）

- RandAffined: 随机仿射变换 (旋转、平移、缩放)
 - RandRotate90d: 随机 90 度旋转 (概率 0.5)
 - RandGaussianNoised: 随机高斯噪声 (概率 0.15)
 - RandAdjustContrastd: 随机对比度调整 (概率 0.15)
4. 归一化: 使用 ScaleIntensityd 进行 CT 图像归一化
 5. 尺寸调整: Resize 到 256×256 (Swin-UNETR 要求输入尺寸为 32 的倍数)
 6. 张量转换: 使用 ToTensord 转换为 PyTorch 张量

2.4 训练策略

2.4.1 损失函数

采用 DiceFocalLoss 作为损失函数, 该损失函数结合了 Dice 损失和 Focal 损失的优点:

$$\text{Loss} = \alpha \cdot \text{DiceLoss} + (1 - \alpha) \cdot \text{FocalLoss} \quad (1)$$

其中 DiceLoss 用于处理类别不平衡问题, FocalLoss 用于聚焦难分类样本。

2.4.2 优化器

使用 AdamW 优化器, 参数设置如下:

- 学习率: 1×10^{-4}
- 权重衰减: 1×10^{-5}

2.4.3 学习率调度

采用余弦退火学习率调度器 (CosineAnnealingLR):

- 最大周期 (T_max): 200 个 epoch
- 最小学习率 (eta_min): 1×10^{-6}

2.4.4 训练配置

- 训练轮数: 200 个 epoch
- 批次大小: 16
- 数据划分: 训练集 80%, 验证集 20%
- 随机种子: 520 (确保实验可复现)

2.5 评估指标

本研究采用以下评估指标：

1. **Dice 系数**：衡量预测与真实分割的重叠程度

$$\text{Dice} = \frac{2 \times |A \cap B|}{|A| + |B|} \quad (2)$$

2. **IoU (Jaccard 系数)**：衡量预测与真实分割的交并比

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (3)$$

3. **mDice/mIoU**：所有类别 Dice/IoU 的平均值

3 项目结果

3.1 实验数据

本研究使用的数据集包含胸部 CT 图像及其对应的分割掩码，具体统计信息如下：

表 2: 数据集统计信息

项目	数值
图像总数	1000 对
训练集	800 对
验证集	200 对
图像尺寸	512×512
分割类别	3 类（肺、心脏、气管）

3.2 定量评估结果

3.2.1 训练轮次对比

表3和表4分别展示了两轮训练的定量评估结果：

表 3: 训练 1 的定量评估结果（部分轮次）

Epoch	Dice_Lung	IoU_Lung	Dice_Heart	IoU_Heart	Dice_Trachea	IoU_Trachea	mDice	mIoU
10	0.8308	0.8072	0.8785	0.8627	0.6852	0.6393	0.7982	0.7697
50	0.8895	0.8722	0.9009	0.8887	0.8722	0.8499	0.8876	0.8703
100	0.9065	0.8874	0.8978	0.8844	0.9327	0.9085	0.9124	0.8934
150	0.9054	0.8854	0.9156	0.9006	0.9302	0.9032	0.9171	0.8964
200	0.9622	0.9426	0.8433	0.8296	0.9148	0.8861	0.9068	0.8861

表 4: 训练 2 的定量评估结果 (部分轮次)

Epoch	Dice_Lung	IoU_Lung	Dice_Heart	IoU_Heart	Dice_Trachea	IoU_Trachea	mDice	mIoU
10	0.8148	0.7888	0.6385	0.6202	0.5224	0.4873	0.6586	0.6321
50	0.8313	0.8057	0.7383	0.7209	0.8629	0.8331	0.8109	0.7865
100	0.9113	0.8905	0.8351	0.8199	0.9225	0.8959	0.8896	0.8688
150	0.9621	0.9420	0.8936	0.8799	0.9412	0.9183	0.9323	0.9134
200	0.9664	0.9480	0.8995	0.8860	0.9455	0.9242	0.9371	0.9194

3.2.2 最佳结果对比

表 5: 两次训练的最佳结果对比

指标	训练 1 最佳	训练 2 最佳	提升幅度	最佳 Epoch
Dice_Lung	0.9633	0.9664	+0.32%	190
IoU_Lung	0.9422	0.9480	+0.62%	200
Dice_Heart	0.9157	0.9054	-1.12%	170
IoU_Heart	0.9038	0.8920	-1.31%	190
Dice_Trachea	0.9458	0.9458	0%	170/190
IoU_Trachea	0.9226	0.9243	+0.18%	190
mDice	0.9388	0.9390	+0.02%	190
mIoU	0.9196	0.9212	+0.17%	190

3.3 训练过程分析

3.3.1 损失曲线

图2展示了两训练的损失变化趋势:




图 2: 训练损失曲线对比

损失曲线分析:

- 训练 1 在第 65 个 epoch 左右损失突然下降, 随后趋于稳定
- 训练 2 的损失下降更为平稳, 在第 125 个 epoch 后趋于稳定
- 训练 2 的最终损失 (约 0.3037) 低于训练 1 (约 0.3060)

3.3.2 评估指标变化趋势

图3展示了关键评估指标随训练轮次的变化:




图 3: 评估指标变化趋势

指标趋势分析:

- 肺部分割性能在训练中期达到较高水平, 后期略有波动
- 心脏分割性能相对稳定, 但在训练后期略有下降
- 气管分割性能持续提升, 在训练后期达到最佳

3.4 分割效果可视化

图4展示了典型样本的分割效果:




图 4: 胸部 CT 图像分割效果可视化

分割效果分析：

- 肺部分割边界清晰，能够准确区分肺组织与周围结构
- 心脏分割能够捕获心脏的整体轮廓
- 气管分割效果良好，能够识别细小的气道结构

4 项目结论

4.1 主要贡献

本研究在胸部 CT 多器官分割任务中取得了以下主要贡献：

1. **模型选择**：采用 Swin-UNETR v2 架构，充分利用 Transformer 的全局建模能力和 U-Net 的局部特征提取能力
2. **损失函数优化**：使用 DiceFocalLoss 有效处理类别不平衡问题，提升小器官（如气管）的分割性能
3. **数据增强策略**：综合运用多种空间和强度变换，增强模型的泛化能力
4. **学习率调度**：采用余弦退火策略，在训练后期以较小学习率进行精细调整

4.2 创新点

- 将 Swin-UNETR v2 架构首次应用于胸部 CT 多器官分割任务
- 结合多种数据增强技术，提升模型对不同扫描条件的适应性
- 针对医学图像特点优化损失函数和训练策略

4.3 局限性

本研究存在以下局限性：

- **数据集规模有限**：仅使用 1000 对图像进行训练，可能影响模型的泛化能力
- **类别不平衡**：尽管采用了 DiceFocalLoss，心脏分割性能仍相对较低
- **计算资源需求**：Swin-UNETR 模型较大，训练需要较高配置的 GPU
- **缺乏外部验证**：未在独立的外部数据集上进行验证

4.4 未来改进方向

针对上述局限性，未来工作可从以下方面进行改进：

1. **扩大数据集**：收集更多不同来源、不同设备的 CT 图像
2. **迁移学习**：利用预训练模型进行迁移学习，提升小样本学习能力
3. **多模态融合**：结合 MRI 等其他模态数据，提升分割精度

4. **后处理优化**: 引入形态学操作或 CRF 等后处理方法, 优化分割边界
5. **模型压缩**: 通过量化、剪枝等技术压缩模型, 便于临床部署

参考文献

1. Hatamizadeh, A., et al. (2022). Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images. In Proceedings of MICCAI.
2. Ronneberger, O., et al. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. In Proceedings of MICCAI.
3. Liu, Z., et al. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. In Proceedings of ICCV.
4. Lin, T. Y., et al. (2017). Focal Loss for Dense Object Detection. In Proceedings of ICCV.
5. Cardoso, M. J., et al. (2022). MONAI: An Open-Source Framework for Deep Learning in Healthcare. arXiv preprint arXiv:2211.02701.