

Multi-Organ Segmentation of Chest CT Images Based on Swin-UNETR v2

基于 Swin-UNETR v2 的胸部 CT 图像多器官分割

Author Name

Department of Medical Imaging, University Name

author@university.edu.cn

摘要

胸部 CT 图像多器官分割是计算机辅助诊断系统的核心环节，对肺部疾病筛查、心脏功能评估及气道病变分析具有重要临床意义。本研究提出一种基于 Swin-UNETR v2 架构的胸部 CT 多器官分割方法，以 Swin Transformer 层级编码器提取多尺度全局特征，经 U-Net 式解码器与跳跃连接逐步恢复空间分辨率，实现对肺 (Lung)、心脏 (Heart) 和气管 (Trachea) 三类器官的端到端精确分割。训练阶段采用 DiceFocalLoss 复合损失函数缓解类别不平衡问题，配合 AdamW 优化器与余弦退火学习率调度策略，在 Kaggle Chest CT Segmentation 数据集上进行了 200 轮训练。两组独立实验的最优模型在测试集上分别取得 0.9388 和 0.9390 的平均 Dice 系数，其中肺部分割 Dice 系数最高达 0.9664，心脏 0.9054，气管 0.9458。实验结果表明，所提方法能够有效捕获胸部 CT 图像中不同尺度器官的语义特征，在多器官分割任务上取得了具有竞争力的性能。

关键词：胸部 CT；多器官分割；Swin-UNETR；DiceFocalLoss；医学图像分析

摘要

Multi-organ segmentation of chest CT images is a critical component of computer-aided diagnosis systems, with significant clinical implications for lung disease screening, cardiac function assessment, and airway pathology analysis. This study proposes a chest CT multi-organ segmentation method based on the Swin-UNETR v2 architecture, which employs a hierarchical Swin Transformer encoder to extract multi-scale global features and a U-Net-style decoder with skip connections to progressively recover spatial resolution, achieving end-to-end precise segmentation of three organ classes: lung, heart, and trachea. During training, the DiceFocalLoss

composite loss function is adopted to alleviate class imbalance, combined with the AdamW optimizer and cosine annealing learning rate scheduling. Two independent training runs were conducted for 200 epochs on the Kaggle Chest CT Segmentation dataset. The best models from the two runs achieved mean Dice coefficients of 0.9388 and 0.9390 on the test set, respectively, with per-organ Dice scores of up to 0.9664 for lung, 0.9054 for heart, and 0.9458 for trachea. Experimental results demonstrate that the proposed method effectively captures semantic features of organs at varying scales in chest CT images, achieving competitive performance on the multi-organ segmentation task.

Keywords: Chest CT; Multi-organ Segmentation; Swin-UNETR; DiceFocalLoss; Medical Image Analysis

1 Introduction

胸部计算机断层扫描 (Computed Tomography, CT) 是临床胸部疾病诊断最常用的影像学检查手段, 其高分辨率横断面成像能够清晰显示肺部、心脏及气道等关键解剖结构 [1]。精确的器官分割是后续定量分析与计算机辅助诊断 (Computer-Aided Diagnosis, CAD) 系统的基础, 在以下场景中具有重要应用价值: (1) 肺部疾病诊断, 如肺结节检测、肺气肿量化与肺炎范围评估; (2) 心脏功能评估, 包括心室体积测量与心壁厚度分析; (3) 气道病变分析, 如气管狭窄与支气管扩张评估; (4) 胸部手术规划与导航。

近年来, 深度学习技术在医学影像分割领域取得了突破性进展。Ronneberger 等人 [2] 提出的 U-Net 架构凭借编码器-解码器结构与跳跃连接, 成为医学图像分割的里程碑方法。Isensee 等人 [3] 提出的 nnU-Net 通过自适应配置策略进一步提升了分割性能。然而, 基于卷积神经网络 (CNN) 的方法受限于局部感受野, 难以建模长距离空间依赖关系。为解决这一局限, Transformer 架构逐渐被引入医学影像分割领域: Chen 等人 [4] 提出 TransUNet, 将 Transformer 编码器与 U-Net 解码器级联; Wang 等人 [5] 提出 UCTransNet, 在跳跃连接中引入通道注意力机制。Liu 等人 [6] 提出的 Swin Transformer 通过局部窗口自注意力与移位窗口机制, 在保持线性计算复杂度的同时实现了高效的全局建模。Hatamizadeh 等人 [1] 进一步提出 Swin-UNETR, 将 Swin Transformer 编码器与 U-Net 解码器深度融合, 在多项医学分割基准上取得了领先性能。

尽管上述方法取得了显著进展, 胸部 CT 多器官分割仍面临以下挑战: (1) 器官形态变异大, 个体间解剖差异显著; (2) 小器官 (如气管) 像素占比低, 类别不平衡问题突出; (3) 器官边界模糊, 相邻结构灰度差异小; (4) 不同扫描设备与参数导致的图像质量差异影响模型泛化能力。

针对上述问题, 本研究采用 Swin-UNETR v2 架构, 结合 DiceFocalLoss 复合损失函数与余弦退火学习率调度策略, 在 Kaggle Chest CT Segmentation 数据集上实现了肺、心脏和气管三类器官的高精度分割。本文的主要贡献如下:

1. 采用 Swin-UNETR v2 架构, 充分利用 Swin Transformer 的全局建模能力与 U-Net 解码器的精确定位能力;
2. 引入 DiceFocalLoss 复合损失函数, 有效缓解类别不平衡问题, 提升小器官分割性能;
3. 设计综合数据增强策略, 包含空间变换与强度变换, 增强模型对不同扫描条件的鲁棒性;
4. 通过两组独立实验验证方法的有效性与可复现性, 最优模型取得 0.9390 的平均 Dice 系数。




图 1 Architecture of Swin-UNETR v2. The encoder extracts hierarchical features through shifted window self-attention, while the decoder recovers spatial resolution via transposed convolution and skip connections.

2 Methodology

2.1 Network Architecture

本研究采用 Swin-UNETR v2 作为分割网络, 其整体架构如图 1 所示。该架构由 Swin Transformer 编码器、瓶颈层与 CNN 解码器三部分组成。

2.1.1 Swin Transformer Encoder

Swin Transformer 编码器 [6] 通过层级式特征提取与局部窗口自注意力机制, 在保持线性计算复杂度的同时捕获多尺度全局特征。其核心操作包括:

1. **Patch Partition:** 将输入图像分割为不重叠的 patch, 每个 patch 经线性嵌入后作为 token 序列输入;
2. **Window Multi-Head Self-Attention (W-MSA):** 在固定大小的局部窗口内计算自注意力, 复杂度与图像尺寸呈线性关系;
3. **Shifted Window MSA (SW-MSA):** 通过移位窗口实现跨窗口信息交互, 消除窗口边界的分割伪影;
4. **Patch Merging:** 在相邻 Stage 间合并相邻 patch, 降低空间分辨率的同时增加特征维度。

编码器包含 4 个 Stage, 特征维度依次为 $\{48, 96, 192, 384\}$, 空间分辨率逐层降采样为 $\{128, 64, 32, 16\}$ 。

表 1 Network configuration of Swin-UNETR v2.

Parameter	Value
Input channels	1 (grayscale CT)
Output channels	3 (lung, heart, trachea)
Feature size	48
Spatial dimensions	2D
Gradient checkpointing	Enabled
Architecture version	v2

表 2 Data preprocessing and augmentation pipeline.

Transform	Parameters	Train	Inference
LoadImaged	keys={image, label}	✓	✓
EnsureChannelFirstd	keys={image, label}	✓	✓
ScaleIntensityd	keys={image}	✓	✓
RandFlipd	prob=0.5, axis={0,1}	✓	—
RandAffined	rotate= ± 0.2 rad, translate= $\pm 10\%$, scale= $\pm 10\%$	✓	—
RandRotate90d	prob=0.5	✓	—
RandGaussianNoised	prob=0.15, std=0.02	✓	—
RandAdjustContrastd	prob=0.15, $\gamma \in [0.8, 1.2]$	✓	—
Resized	size= 256×256 , bilinear/nearest	✓	✓
ToTensord	keys={image, label}	✓	✓

2.1.2 CNN Decoder

解码器采用转置卷积 (Transposed Convolution) 逐步上采样特征图, 并通过跳跃连接将编码器对应层级的特征与解码器特征拼接 (Concatenation), 经卷积块融合后恢复空间细节。该设计确保了分割边界的精确定位。

2.1.3 Network Configuration

表 1列出了本研究所使用的网络参数配置。

2.2 Data Preprocessing

数据预处理流程基于 MONAI 框架 [7] 构建, 训练阶段与推理阶段的变换组合如表 2所示。

数据增强策略包含两类变换: (1) **空间变换** (RandFlipd、RandAffined、RandRotate90d), 通过几何变换增强模型对器官位置与形态变化的鲁棒性; (2) **强度变换** (RandGaussianNoised、RandAdjustContrastd), 通过模拟噪声与对比度差异增强模型对不同扫描条件的适应性。输入图像统一缩放至 256×256 , 以满足 Swin Transformer 对输入尺寸为 32 倍数的要求。

2.3 Loss Function

本研究采用 DiceFocalLoss 作为训练损失函数，该函数为 Dice Loss [8] 与 Focal Loss [9] 的加权组合：

$$\mathcal{L} = \lambda_{\text{Dice}} \cdot \mathcal{L}_{\text{Dice}} + \lambda_{\text{Focal}} \cdot \mathcal{L}_{\text{Focal}} \quad (1)$$

其中，Dice Loss 定义为：

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i (p_i \cdot g_i) + \epsilon}{\sum_i p_i + \sum_i g_i + \epsilon} \quad (2)$$

Focal Loss 定义为：

$$\mathcal{L}_{\text{Focal}} = -\alpha_t (1 - p_t)^\gamma \log(p_t) \quad (3)$$

式中 p_i 和 g_i 分别为预测概率与真实标签像素值， ϵ 为平滑因子， α_t 为类别权重， γ 为聚焦参数。Dice Loss 直接优化分割重叠度，对类别不平衡具有天然鲁棒性；Focal Loss 通过降低易分类样本的损失权重，使模型聚焦于难分类区域（如器官边界与小器官）。MONAI 框架中 DiceFocalLoss 默认设置 $\lambda_{\text{Dice}} = \lambda_{\text{Focal}} = 1.0$ ， $\gamma = 2.0$ ，并启用 Sigmoid 激活与背景通道包含。

2.4 Optimization

模型训练采用 AdamW 优化器 [10]，其将权重衰减与梯度更新解耦，相比标准 Adam 具有更好的正则化效果。学习率调度采用余弦退火策略（Cosine Annealing）：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \frac{t\pi}{T_{\max}} \right) \quad (4)$$

其中 $\eta_{\max} = 1 \times 10^{-4}$ ， $\eta_{\min} = 1 \times 10^{-6}$ ， $T_{\max} = 200$ 。该策略在训练初期以较大学习率快速收敛，后期以极小学习率精细调整，有效缓解 Transformer 架构对学习率敏感导致的训练震荡问题。

2.5 Evaluation Metrics

本研究采用以下指标评估分割性能：

Dice Similarity Coefficient (DSC)：衡量预测与真实分割的重叠程度：

$$\text{Dice} = \frac{2|A \cap B|}{|A| + |B|} \quad (5)$$

Intersection over Union (IoU)：又称 Jaccard 系数，衡量预测与真实分割的交并比：

表 3 Dataset statistics.

Item	Description
Total image-mask pairs	1,000
Training set	800 (80%)
Test set	200 (20%)
Image format	JPG, 512×512
Mask format	JPG (RGB), threshold ≥ 240
Segmentation classes	Lung (R), Heart (G), Trachea (B)
Pair mapping	<code>train.csv</code> : ImageId $\leftrightarrow$ MaskId

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (6)$$

Mean Dice / Mean IoU: 所有类别 Dice/IoU 的算术平均值, 用于综合评估多类别分割性能。

3 Experiments and Results

3.1 Dataset

本研究使用 Kaggle 平台公开的 Chest CT Segmentation 数据集¹, 包含胸部 CT 横断面图像及对应的三器官分割掩码。数据集统计信息如表 3 所示。

掩码为 RGB 三通道图像, 像素值 ≥ 240 的区域为有效分割区域。原始数据集通道顺序为 BGR (OpenCV 格式), 训练与测试代码中通过通道交换操作 `labels[:, [2,1,0], :, :]` 将其转换为 RGB 顺序, 对应 [Lung, Heart, Trachea]。

3.2 Training Configuration

表 4 汇总了完整的训练配置。

两组独立实验 (Experiment 1 与 Experiment 2) 采用相同的超参数配置与随机种子, 以验证结果的可复现性。

3.3 Quantitative Results

3.3.1 Per-Epoch Evaluation

表 5 与表 6 分别展示了两组实验在不同训练轮次的定量评估结果。

¹<https://www.kaggle.com/datasets/polomarco/chest-ct-segmentation>

表 4 Training configuration.

Hyperparameter	Value
Optimizer	AdamW [10]
Learning rate	1×10^{-4}
Weight decay	1×10^{-5}
LR scheduler	CosineAnnealingLR ($T_{\max} = 200$, $\eta_{\min} = 10^{-6}$)
Loss function	DiceFocalLoss ($\lambda_{\text{Dice}} = \lambda_{\text{Focal}} = 1.0$)
Batch size	16
Training epochs	200
Data split	80% train / 20% test
Random seed	520
Checkpoint interval	Every 10 epochs

表 5 Quantitative evaluation results of Experiment 1 at selected epochs.

Epoch	DSC_L	IoU_L	DSC_H	IoU_H	DSC_T	IoU_T	mDSC	mIoU
10	0.8308	0.8072	0.8785	0.8627	0.6852	0.6393	0.7982	0.7697
50	0.8895	0.8722	0.9009	0.8887	0.8722	0.8499	0.8876	0.8703
100	0.9065	0.8874	0.8978	0.8844	0.9327	0.9085	0.9124	0.8934
150	0.9054	0.8854	0.9156	0.9006	0.9302	0.9032	0.9171	0.8964
170	0.9612	0.9415	0.9043	0.8914	0.9458	0.9226	0.9371	0.9185
180	0.9632	0.9428	0.9132	0.8997	0.9398	0.9165	0.9388	0.9196
200	0.9622	0.9426	0.8433	0.8296	0.9148	0.8861	0.9068	0.8861

DSC_L/IoU_L: Lung; DSC_H/IoU_H: Heart; DSC_T/IoU_T: Trachea.

表 6 Quantitative evaluation results of Experiment 2 at selected epochs.

Epoch	DSC_L	IoU_L	DSC_H	IoU_H	DSC_T	IoU_T	mDSC	mIoU
10	0.8148	0.7888	0.6385	0.6202	0.5224	0.4873	0.6586	0.6321
50	0.8313	0.8057	0.7383	0.7209	0.8629	0.8331	0.8109	0.7865
100	0.9113	0.8905	0.8351	0.8199	0.9225	0.8959	0.8896	0.8688
150	0.9621	0.9420	0.8936	0.8799	0.9412	0.9183	0.9323	0.9134
170	0.9650	0.9461	0.8958	0.8823	0.9449	0.9231	0.9352	0.9172
190	0.9660	0.9475	0.9054	0.8920	0.9458	0.9243	0.9390	0.9212
200	0.9664	0.9480	0.8995	0.8860	0.9455	0.9242	0.9371	0.9194

DSC_L/IoU_L: Lung; DSC_H/IoU_H: Heart; DSC_T/IoU_T: Trachea.

表 7 Best performance comparison between two experiments. Bold values indicate the better result.

Metric	Exp. 1 Best	Exp. 2 Best	Diff.	Best Epoch
DSC_Lung	0.9633	0.9664	+0.31%	190
IoU_Lung	0.9428	0.9480	+0.52%	200
DSC_Heart	0.9157	0.9054	−1.03%	170
IoU_Heart	0.9038	0.8920	−1.18%	190
DSC_Trachea	0.9458	0.9458	0.00%	170/190
IoU_Trachea	0.9226	0.9243	+0.17%	190
mDSC	0.9388	0.9390	+0.02%	190
mIoU	0.9196	0.9212	+0.16%	190




图 2 Training loss curves of two independent experiments. Both exhibit a two-phase convergence pattern with an initial rapid descent followed by gradual stabilization.

3.3.2 Best-Performance Comparison

表 7 汇总了两组实验各指标的最优值及对应训练轮次。两组实验的最优 mDice 分别为 0.9388 (Epoch 180) 与 0.9390 (Epoch 190)，差异仅为 0.02%，验证了方法的可复现性。

3.4 Training Dynamics

3.4.1 Loss Convergence

图 2 展示了两组实验的训练损失变化趋势。两组实验均呈现两阶段收敛特征：第一阶段损失快速下降，第二阶段在更低损失水平缓慢收敛。

值得注意的是，两组实验均在训练中期出现了显著的损失跳变现象：Experiment 1 在 Epoch 65 附近损失从 0.54 骤降至 0.40，Experiment 2 在 Epoch 25 附近损失从 0.58 骤降至 0.51。这一现象可归因于余弦退火调度器在训练中期学习率仍较大时，模型参数




图 3 Per-organ DSC progression of Experiment 2. Lung segmentation converges fastest, while heart and trachea show more gradual improvement with late-stage fluctuations.

跨越损失曲面鞍点所致。Experiment 2 的最终收敛损失 (0.3037) 略低于 Experiment 1 (0.3060)，表明其收敛更为充分。

3.4.2 Per-Organ Dice Score Progression

图 3展示了 Experiment 2 中各器官 Dice 系数随训练轮次的变化趋势。

从图 3可观察到以下规律：

- **肺**：DSC 在训练早期即快速上升至 0.90 以上，后期稳定在 0.96 附近。肺组织在 CT 图像中占比大、对比度高，因此最易分割。
- **心脏**：DSC 上升较为缓慢，在 Epoch 130 后趋于 0.90，但 Epoch 200 出现轻微下降 (0.8995)，可能由于后期学习率过小导致模型在心脏区域的拟合能力减弱。
- **气管**：DSC 在 Epoch 30 出现跳变 (从 0.61 升至 0.84)，与损失曲线的跳变点吻合。气管像素占比最小，但得益于 DiceFocalLoss 对难分类样本的聚焦效应，最终 DSC 达到 0.9455，超过心脏分割性能。

3.5 Qualitative Visualization

图 4展示了典型样本的分割效果可视化。模型在肺、心脏和气管三类器官上均取得了视觉上令人满意的分割结果，预测掩码与真实掩码高度吻合。

3.6 Comparative Analysis

综合两组实验结果，可得出以下分析结论：




图 4 Qualitative segmentation results. (a) Original CT image. (b) Ground truth annotation with color-coded organ masks. (c) Model prediction showing high overlap with ground truth across all three organ classes.

1. **器官尺度与分割难度**: 肺 ($DSC > 0.96$) > 气管 ($DSC \approx 0.95$) > 心脏 ($DSC \approx 0.90$)。肺组织占比最大且对比度最高, 最易分割; 气管虽像素占比最小, 但形态规则且灰度差异显著, DiceFocalLoss 有效提升了其分割性能; 心脏与周围纵隔组织灰度差异小、边界模糊, 是分割难度最大的器官。
2. **训练稳定性**: Experiment 2 的损失收敛更为平滑, 最终测试性能略优于 Experiment 1, 表明模型在充分训练后可达到稳定的分割性能。
3. **后期性能波动**: 两组实验在 Epoch 200 时心脏 DSC 均出现下降 (Experiment 1: 0.8433; Experiment 2: 0.8995), 而 Epoch 170–190 为最优区间。这提示在实际应用中应采用基于验证集的早停策略 (Early Stopping), 而非固定训练轮数。

4 Conclusion

本研究针对胸部 CT 图像多器官分割任务, 提出了一种基于 Swin-UNETR v2 的端到端分割方法。通过将 Swin Transformer 层级编码器与 U-Net 式解码器深度融合, 该方法能够同时捕获全局语义信息与局部空间细节。结合 DiceFocalLoss 复合损失函数、综合数据增强策略与余弦退火学习率调度, 在 Kaggle Chest CT Segmentation 数据集上取得了 0.9390 的平均 Dice 系数, 其中肺、心脏和气管的 Dice 系数分别达到 0.9664、0.9054 和 0.9458。

Limitations

本研究存在以下局限性: (1) 数据集规模有限 (1,000 对图像), 模型的泛化能力有待在更大规模、多中心数据集上验证; (2) 心脏分割性能 ($DSC \approx 0.90$) 仍有提升空间, 其与周围组织的低对比度是主要瓶颈; (3) Swin-UNETR 模型参数量较大, 训练需 GPU 资源, 临床部署存在效率挑战; (4) 缺乏与 U-Net、TransUNet 等基线方法的系统

对比实验。

Future Work

未来工作可从以下方向展开：(1) 引入自监督预训练策略，利用大规模无标注 CT 数据提升特征表示能力；(2) 探索 3D 分割方案，充分利用 CT 体积数据的层间连续性；(3) 引入注意力门控 (Attention Gate) 或边界感知模块，提升心脏等模糊边界器官的分割精度；(4) 通过知识蒸馏与模型剪枝压缩模型，降低推理延迟以满足临床实时性需求；(5) 在多中心外部数据集上进行验证，评估模型的跨域泛化能力。

References

- [1] Ali Hatamizadeh et al. “Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2022, pp. 272–282.
- [2] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-Net: Convolutional Networks for Biomedical Image Segmentation”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2015, pp. 234–241.
- [3] Fabian Isensee et al. “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation”. In: *Nature Methods*. Vol. 18. 2. 2021, pp. 203–211.
- [4] Jieneng Chen et al. “TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation”. In: *arXiv preprint arXiv:2102.04306* (2021).
- [5] Haonan Wang et al. “UCTransNet: Rethinking the Skip Connections in U-Net from a Channel-wise Perspective with Transformer”. In: *AAAI Conference on Artificial Intelligence (AAAI)* (2022).
- [6] Ze Liu et al. “Swin Transformer: Hierarchical Vision Transformer using Shifted Windows”. In: *IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 10012–10022.
- [7] M. Jorge Cardoso et al. “MONAI: An open-source framework for deep learning in healthcare”. In: *arXiv preprint arXiv:2211.02701* (2022).
- [8] Fausto Milletari, Nassir Navab, and Seyed-Ahmad Ahmadi. “V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation”. In: (2016), pp. 565–571.

- [9] Tsung-Yi Lin et al. “Focal Loss for Dense Object Detection”. In: *IEEE International Conference on Computer Vision (ICCV)*. 2017, pp. 2980–2988.
- [10] Ilya Loshchilov and Frank Hutter. “Decoupled Weight Decay Regularization”. In: *arXiv preprint arXiv:1711.05101* (2017).