

《医学图像处理技术》 期末项目报告

题目：任务二 Chest CT Segmentation

组号：15

小组成员姓名：俞烨，张天硕，张璟文，张鸿榜，
吴君凯，黄绍华，陈飞翔，刘华胜

小组成员学号：102301116, 102301113, 102301114, 102301115,
102301121, 102301137, 102301142, 022304111

评分：

1、语言与排版（25 分）：_____

2、问题难易程度（25 分）：_____

3、实践掌握程度（50 分）：_____

总分：_____

Abstract:Multi-organ segmentation of chest CT images constitutes a critical component of computer-aided diagnosis systems, with significant clinical implications for lung disease screening, cardiac function assessment, and airway pathology analysis. This study proposes a chest CT multi-organ segmentation method based on the Swin-UNETR v2 architecture, which employs a hierarchical Swin Transformer encoder to extract multi-scale global features and a U-Net-style decoder with skip connections to progressively recover spatial resolution, achieving end-to-end precise segmentation of three organ classes: lung, heart, and trachea.

During training, the DiceFocalLoss composite loss function is adopted to alleviate class imbalance, combined with the AdamW optimizer and cosine annealing learning rate scheduling. Three experiments were conducted on the Kaggle Chest CT Segmentation dataset: Experiment I (Swin-UNETR v2 baseline), Experiment II (Swin-UNETR v2 with parameter optimization verification), and Experiment III (UNet++ with pretrained encoder). The best model from Experiment III achieves a mean Dice coefficient of 0.9661 on the test set, with per-organ Dice scores of 0.9702 for lung, 0.9718 for heart, and 0.9563 for trachea. A reference baseline using U-Net with EfficientNet-B2 encoder and BCEDiceLoss achieved val_dice of 0.968 on a different data split.

Experimental results demonstrate that the UNet++ with pretrained encoder effectively captures semantic features of organs at varying scales in chest CT images, achieving the best performance on the multi-organ segmentation task. This report provides comprehensive details on the methodology, implementation, training dynamics, and results analysis, along with complete experimental records and visualization examples.

Keywords: Chest CT, Multi-organ Segmentation, Swin-UNETR, DiceFocalLoss, Medical Image Analysis

摘要：胸部 CT 图像多器官分割是计算机辅助诊断系统的核心环节，对肺部疾病筛查、心脏功能评估及气道病变分析具有重要临床意义。本研究提出一种基于 Swin-UNETR v2 架构的胸部 CT 多器官分割方法，以 Swin Transformer 层级编码器提取多尺度全局特征，经 U-Net 式解码器与跳跃连接逐步恢复空间分辨率，实现对肺（Lung）、心脏（Heart）和气管（Trachea）三类器官的端到端精确分割。

训练阶段采用 DiceFocalLoss 复合损失函数缓解类别不平衡问题，配合 AdamW 优化器与余弦退火学习率调度策略，在 Kaggle Chest CT Segmentation 数据集上进行了三组实验：实验一（Swin-UNETR v2 基准模型）、实验二（Swin-UNETR v2 参数优化验证）和实验三（基于预训练 UNet++ 的对比实验）。实验三的最优模型在测试集上取得了 0.9661 的平均 Dice 系数（mDSC），肺部分割 Dice 系数最高达 0.9702，心脏 0.9718，气管 0.9563。此外，基于 Kaggle 开源示例的参考基线（U-Net + EfficientNet-B2 编码器 + BCEDiceLoss）在不同数据划分上取得了 val_dice=0.968 的结果。

实验结果表明，采用预训练编码器的 UNet++ 能够有效捕获胸部 CT 图像中不同尺度器官的语义特征，在多器官分割任务上取得了最优性能。本报告详细阐述了研究方法、实现过程、训练动态和结果分析，提供了完整的实验记录和可视化示例。

关键词：胸部 CT；多器官分割；Swin-UNETR；DiceFocalLoss；医学图像分析

目录

1	引言	3
1.1	主要贡献	3
1.2	报告结构	4
2	研究方法	4
2.1	Swin-UNETR v2 架构	4
2.1.1	Swin Transformer 编码器	5
2.1.2	CNN 解码器	5
2.1.3	网络配置	5
2.2	基于 UNet++ 的对比模型	6
2.2.1	EfficientNet-B2 编码器	6
2.2.2	嵌套跳跃路径解码器	6
2.2.3	网络配置	6
2.3	架构对比	6
2.4	参考基线	7
2.5	数据预处理	8
2.6	损失函数	8
2.7	优化与训练	9
3	实验设置	10
3.1	数据集	10
3.2	环境配置	11
3.2.1	训练配置	11
3.3	实验设计	12
3.4	评价指标	13
4	实验结果与分析	14
4.1	定量结果	14
4.1.1	实验一：基于 Swin-UNETR v2 的基准模型结果	14
4.1.2	实验二：Swin-UNETR v2 参数优化实验结果	14
4.1.3	实验三：基于预训练 UNet++ 的对比实验结果	15
4.1.4	最佳性能对比	15
4.2	训练动态	16
4.2.1	损失收敛分析	16

4.2.2	各器官 Dice 系数变化趋势	18
4.2.3	各实验最佳模型性能对比	20
4.3	Swin-UNETR v2 与 UNet++ 对比分析	20
4.3.1	分割精度对比	20
4.3.2	收敛速度对比	21
4.3.3	训练效率对比	21
4.4	定性可视化	21
5	讨论	22
5.1	Swin-UNETR v2 与 UNet++ 的对比分析	22
5.2	器官分割难度分析	23
5.3	损失函数的有效性	23
5.4	局限性分析	23
5.5	未来工作展望	24
6	结论	24
	参考文献	25

1 引言

胸部计算机断层扫描 (Computed Tomography, CT) 是临床胸部疾病诊断最常用的影像学检查手段, 其高分辨率横断面成像能够清晰显示肺部、心脏及气道等关键解剖结构 [1]。精确的器官分割是后续定量分析与计算机辅助诊断 (Computer-Aided Diagnosis, CAD) 系统的基础, 在以下场景中具有重要应用价值: (1) 肺部疾病诊断, 如肺结节检测、肺气肿量化与肺炎范围评估; (2) 心脏功能评估, 包括心室体积测量与心壁厚度分析; (3) 气道病变分析, 如气管狭窄与支气管扩张评估; (4) 胸部手术规划与导航。

近年来, 深度学习技术在医学影像分割领域取得了突破性进展。Ronneberger 等人 [2] 提出的 U-Net 架构凭借编码器-解码器结构与跳跃连接, 成为医学图像分割的里程碑方法。Isensee 等人 [3] 提出的 nnU-Net 通过自适应配置策略进一步提升了分割性能。然而, 基于卷积神经网络 (CNN) 的方法受限于局部感受野, 难以建模长距离空间依赖关系。

为解决这一局限, Transformer 架构逐渐被引入医学影像分割领域: Chen 等人 [4] 提出 TransUNet, 将 Transformer 编码器与 U-Net 解码器级联; Wang 等人 [5] 提出 UCTransNet, 在跳跃连接中引入通道注意力机制。Liu 等人 [6] 提出的 Swin Transformer 通过局部窗口自注意力与移位窗口机制, 在保持线性计算复杂度的同时实现了高效的全局建模能力。Hatamizadeh 等人 [1] 进一步提出 Swin-UNETR, 将 Swin Transformer 编码器与 U-Net 解码器深度融合, 在多项医学分割基准上取得了领先性能。

尽管上述方法取得了显著进展, 胸部 CT 多器官分割仍面临以下挑战: (1) 器官形态变异大, 个体间解剖差异显著; (2) 小器官 (如气管) 像素占比低, 类别不平衡问题突出; (3) 器官边界模糊, 相邻结构灰度差异小; (4) 不同扫描设备与参数导致的图像质量差异影响模型泛化能力。

针对上述问题, 本研究采用 Swin-UNETR v2 与 UNet++ 两种架构进行对比研究。Swin-UNETR v2 结合 DiceFocalLoss 复合损失函数与余弦退火学习率调度策略, 在 Kaggle Chest CT Segmentation 数据集上实现了肺、心脏和气管三类器官的高精度分割; UNet++ 采用 EfficientNet-B2 预训练编码器与嵌套跳跃路径解码器, 以更轻量的数据增强策略和更大的批大小进行训练, 取得了更优的分割性能。

1.1 主要贡献

本研究的主要贡献包括:

1. 采用 Swin-UNETR v2 架构, 充分利用 Swin Transformer 的全局建模能力与 U-Net 解码器的精确定位能力
2. 引入 UNet++ (EfficientNet-B2 编码器) 作为对比模型, 系统比较 Transformer 架构与 CNN 预训练编码器架构在胸部 CT 分割任务上的性能差异

3. 引入 DiceFocalLoss 复合损失函数，有效缓解类别不平衡问题，提升小器官（气管）的分割性能
4. 设计差异化的数据增强策略与训练配置，分析批大小、数据增强强度对模型收敛与泛化的影响
5. 通过三组独立实验验证方法的有效性与参数优化的可复现性，最优模型（UNet++）取得 0.9661 的平均 Dice 系数，Swin-UNETR v2 最优达 0.9390
6. 提供完整的实现代码、训练记录和实验报告，便于后续研究复现与扩展

1.2 报告结构

本报告其余部分安排如下：第 2 节介绍研究方法，包括 Swin-UNETR v2 与 UNet++ 两种网络架构、数据预处理、损失函数与训练配置；第 3 节描述实验设置，包括数据集、环境配置、评价指标与实验设计；第 4 节展示实验结果并进行详细分析；第 5 节讨论两种架构的对比分析、方法局限性与未来工作；最后第 6 节总结全文。

2 研究方法

2.1 Swin-UNETR v2 架构

本研究采用 Swin-UNETR v2 作为基线分割网络，其整体架构如图 1所示。该架构由 Swin Transformer 编码器、瓶颈层与 CNN 解码器三部分组成，编码器各 Stage 输出通过跳跃连接传递至解码器对应层级。




图 1. Swin-UNETR v2 架构示意图。编码器通过移位窗口自注意力提取层级特征；解码器通过转置卷积和跳跃连接恢复空间分辨率。各 Stage 标注了特征维度和空间分辨率。

2.1.1 Swin Transformer 编码器

Swin Transformer 编码器 [6] 通过层级式特征提取与局部窗口自注意力机制, 在保持线性计算复杂度的同时捕获多尺度全局特征。给定输入特征 z^{l-1} , 第 l 个 Swin Transformer Block 的计算过程为:

$$\hat{z}^l = \text{W-MSA}(\text{LN}(z^{l-1})) + z^{l-1}, \quad (1)$$

$$z^l = \text{MLP}(\text{LN}(\hat{z}^l)) + \hat{z}^l, \quad (2)$$

$$\hat{z}^{l+1} = \text{SW-MSA}(\text{LN}(z^l)) + z^l, \quad (3)$$

$$z^{l+1} = \text{MLP}(\text{LN}(\hat{z}^{l+1})) + \hat{z}^{l+1}, \quad (4)$$

其中 LN 为 Layer Normalization, W-MSA 与 SW-MSA 分别为常规窗口与移位窗口多头自注意力模块。W-MSA 在固定大小的局部窗口内计算注意力, 复杂度与图像尺寸呈线性关系; SW-MSA 通过移位窗口实现跨窗口信息交互, 消除窗口边界的分割伪影。

相邻 Stage 间通过 Patch Merging 操作合并相邻 patch, 在降低空间分辨率的同时增加特征维度。编码器包含 4 个 Stage, 特征维度依次为 $\{48, 96, 192, 384\}$, 空间分辨率逐层降采样为 $\{128 \times 128, 64 \times 64, 32 \times 32, 16 \times 16\}$ 。

2.1.2 CNN 解码器

解码器采用转置卷积逐步上采样特征图, 并通过跳跃连接将编码器对应层级的特征与解码器特征拼接 (Concatenation), 经卷积块融合后恢复空间细节。该设计确保了分割边界的精确定位能力。

2.1.3 网络配置

表 1 列出了本研究所使用的网络参数配置。

表 1. Swin-UNETR v2 网络配置

参数	值
输入通道数	1 (灰度 CT)
输出通道数	3 (肺、心脏、气管)
特征维度	48
空间维度	2D
梯度检查点	启用 (节省显存)
架构版本	v2

2.2 基于 UNet++ 的对比模型

为系统评估不同架构在胸部 CT 多器官分割任务上的性能差异,本研究引入 UNet++ [7] 作为对比模型。UNet++ 采用嵌套的 U-Net 架构,通过密集的跳跃连接路径弥合编码器与解码器之间的语义鸿沟,其核心设计思想在于逐步缩小编码器特征与解码器特征之间的语义差距。

2.2.1 EfficientNet-B2 编码器

UNet++ 的编码器采用 EfficientNet-B2 [8] 作为骨干网络,并加载 ImageNet 预训练权重。EfficientNet 通过复合缩放策略统一调整网络深度、宽度和输入分辨率,在保持较高参数效率的同时实现了优异的特征提取能力。B2 变体在精度与计算量之间取得了良好的平衡,其输入分辨率为 256×256 ,与本研究的数据预处理尺寸一致。

相较于 Swin-UNETR v2 从头训练的 Swin Transformer 编码器,预训练的 EfficientNet-B2 编码器具有两方面优势:(1) ImageNet 预训练提供了丰富的低层与中层视觉特征先验,有助于加速收敛并提升特征质量;(2) 卷积架构的局部归纳偏置更适合医学图像中纹理与边界特征的提取。

2.2.2 嵌套跳跃路径解码器

UNet++ 的解码器采用嵌套跳跃连接(Nested Skip Pathways)设计。传统 U-Net 的跳跃连接直接将编码器特征与解码器特征拼接,存在语义差距过大的问题。UNet++ 通过在编码器与解码器之间引入密集的卷积块,逐步缩小语义差距,使传递至解码器的特征更具语义一致性。该设计在医学图像分割中表现尤为突出,能够有效改善器官边界的分割精度。

2.2.3 网络配置

表 2列出了 UNet++ 的网络参数配置。

表 2. UNet++ 网络配置

参数	值
编码器	EfficientNet-B2
编码器权重	ImageNet 预训练
输入通道数	1 (灰度 CT)
输出通道数	3 (肺、心脏、气管)
激活函数	None (DiceFocalLoss 内置 Sigmoid)

2.3 架构对比

表 3对两种架构的核心设计差异进行了系统对比。

表 3. Swin-UNETR v2 与 UNet++ 架构对比

特性	Swin-UNETR v2	UNet++ (EfficientNet-B2)
编码器类型	Swin Transformer	EfficientNet-B2 (CNN)
编码器预训练	无 (从头训练)	ImageNet 预训练
解码器类型	CNN + 跳跃连接	嵌套跳跃路径
特征提取范式	全局自注意力	局部卷积 + 复合缩放
归纳偏置	弱 (需数据驱动学习)	强 (卷积局部性先验)
输出激活	内置于损失函数	内置于损失函数

两种架构的核心差异在于编码器的设计哲学：Swin-UNETR v2 采用 Swin Transformer 编码器，通过移位窗口自注意力机制捕获全局上下文信息，但缺乏局部归纳偏置，需要更多训练数据与更长训练周期来学习视觉特征；UNet++ 采用预训练的 EfficientNet-B2 编码器，卷积架构的局部归纳偏置与 ImageNet 预训练权重为其提供了良好的特征初始化，有利于在有限数据集上快速收敛并达到更高精度。

2.4 参考基线

为客观评估本研究的实验性能，引入 Kaggle 开源示例¹作为参考基线。该基线采用与本研究不同的模型架构和训练策略，具体配置如下：

- **模型**：U-Net（非 UNet++），编码器为 EfficientNet-B2（ImageNet 预训练），使用 segmentation_models_pytorch 库实现
- **损失函数**：BCEDiceLoss（BCE + Dice 组合），而非本研究的 DiceFocalLoss
- **优化器**：Adam（lr=8e-5），而非本研究的 AdamW
- **学习率调度**：ReduceLROnPlateau（监控验证损失，耐心系数为 5），而非 CosineAnnealingLR
- **数据增强**：仅 VerticalFlip（albumentations 库），远轻于本研究的增强策略
- **训练配置**：batch_size=8，100 轮预训练 + 1 轮微调，seed=555
- **数据划分**：采用 train_test_split(random_state=69)，与本研究(random_state=520)不同

该基线在验证集上取得了 val_dice=0.968、val_jaccard=0.949（第 100 轮）的结果。需要注意的是，由于该基线使用了不同的数据划分方式（random_state=69 vs 本研究的 520），其验证集样本分布与本研究不同，因此直接数值对比并非完全公平，仅作为参考。

¹<https://www.kaggle.com/code/polomarco/chest-ct-segmentation-example>

2.5 数据预处理

数据预处理流程基于 MONAI 框架 [9] 构建, 训练时与推理时的变换组合如表 4 所示。由于两种架构的特性差异, Swin-UNETR v2 与 UNet++ 采用了不同强度的数据增强策略。

表 4. 数据预处理与数据增强流程

变换方法	参数	Swin-UNETR 训练	UNet++ 训练	推理
LoadImaged	keys={image, label}	✓	✓	✓
EnsureChannelFirstd	keys={image, label}	✓	✓	✓
ScaleIntensityd	keys={image}	✓	✓	✓
RandFlipd	prob=0.5, axis={0,1}	✓	✓	—
RandAffined	rotate, translate, scale	✓	✓	—
RandRotate90d	prob=0.5	✓	—	—
RandGaussianNoised	prob=0.15, std=0.02	✓	—	—
RandAdjustContrastd	prob=0.15, $\gamma \in [0.8, 1.2]$	✓	—	—
Resized	256×256, bilinear/nearest	✓	✓	✓
ToTensord	keys={image, label}	✓	✓	✓

Swin-UNETR v2 采用了更重的数据增强策略, 包含两类变换: (1) **空间变换** (RandFlipd、RandAffined、RandRotate90d), 通过几何变换增强模型对器官位置与形态变化的鲁棒性; (2) **强度变换** (RandGaussianNoised、RandAdjustContrastd), 通过模拟噪声与对比度差异增强模型对不同扫描条件的适应性。较重的数据增强旨在弥补 Transformer 编码器缺乏局部归纳偏置的不足, 通过增加训练样本的多样性来提升模型的泛化能力。

UNet++ 采用了更轻量的数据增强策略, 仅保留 RandFlipd 与 RandAffined (概率降至 0.3, 变换范围缩小), 去除了 RandRotate90d、RandGaussianNoised 和 RandAdjustContrastd。这一设计基于以下考量: (1) EfficientNet-B2 的 ImageNet 预训练权重已提供良好的特征初始化, 无需通过强数据增强来弥补归纳偏置的不足; (2) 更轻量的数据增强有助于模型更快地学习训练数据的分布特征, 加速收敛; (3) 较大的批大小 (64) 本身提供了更稳定的梯度估计, 部分替代了数据增强的正则化效果。

输入图像统一缩放至 256×256, 以满足 Swin Transformer 对输入尺寸为 32 倍数的要求, 同时与 EfficientNet-B2 的输入分辨率保持一致。

2.6 损失函数

本研究采用 DiceFocalLoss 作为训练损失函数, 该函数为 Dice Loss [10] 与 Focal Loss [11] 的加权组合:

$$\mathcal{L} = \lambda_{\text{Dice}} \cdot \mathcal{L}_{\text{Dice}} + \lambda_{\text{Focal}} \cdot \mathcal{L}_{\text{Focal}} \quad (5)$$

其中, Dice Loss 定义为:

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i (p_i \cdot g_i) + \epsilon}{\sum_i p_i + \sum_i g_i + \epsilon} \quad (6)$$

Focal Loss 定义为:

$$\mathcal{L}_{\text{Focal}} = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (7)$$

式中 p_i 和 g_i 分别为预测概率与真实标签像素值, ϵ 为平滑因子, α_t 为类别权重, γ 为聚焦参数。

Dice Loss 直接优化分割重叠度, 对类别不平衡具有天然鲁棒性; Focal Loss 通过降低易分类样本的损失权重, 使模型聚焦于难分类区域 (如器官边界与小器官)。MONAI 框架中 DiceFocalLoss 默认设置 $\lambda_{\text{Dice}} = \lambda_{\text{Focal}} = 1.0$, $\gamma = 2.0$, 并启用 Sigmoid 激活与背景通道包含。

2.7 优化与训练

模型训练采用 AdamW 优化器 [12], 其将权重衰减与梯度更新解耦, 相比标准 Adam 具有更优的正则化效果。学习率调度采用余弦退火策略 (Cosine Annealing):

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \frac{t\pi}{T_{\max}} \right) \quad (8)$$

其中 $\eta_{\max} = 1 \times 10^{-4}$, $\eta_{\min} = 1 \times 10^{-6}$ 。Swin-UNETR v2 设置 $T_{\max} = 200$, UNet++ 设置 $T_{\max} = 150$ 。该策略在训练初期以较大学习率快速收敛, 后期以极小学习率精细调整, 有效缓解 Transformer 架构对学习率敏感导致的训练震荡问题。完整训练流程如算法 1 所示。

Algorithm 1: 统一训练流程**Hyperparameters:** Epochs T , batch size B , seed $s=520$, model type M **Input:** Dataset $\mathcal{D}$ **Output:** Trained model parameters θ^*

```

1  设置随机种子  $s$ ;
2  if  $M = \text{Swin-UNETR v2}$  then
3      初始化模型  $\theta$  (随机),  $T \leftarrow 200$ ,  $B \leftarrow 16$ ;
4      配置重数据增强 (含 RandRotate90d、RandGaussianNoised 等);
5  else
6      初始化模型  $\theta$  (EfficientNet-B2 加载 ImageNet 预训练权重),  $T \leftarrow 150$ ,  $B \leftarrow 64$ ;
7      配置轻数据增强 (仅 RandFlipd、RandAffined);
8  初始化 AdamW 优化器、CosineAnnealingLR 调度器;
9  for  $t \leftarrow 1$  to  $T$  do
10     从  $\mathcal{D}$  中采样 mini-batch  $\{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^B$ ;
11     预处理:  $\mathbf{y}_i \leftarrow \mathbf{y}_i[:, [2, 1, 0], :, :]$ ; // BGR  $\rightarrow$  RGB
12     前向传播:  $\hat{\mathbf{y}}_i \leftarrow f_{\theta}(\mathbf{x}_i)$ ;
13     计算损失:  $\mathcal{L} = \text{DiceFocalLoss}(\hat{\mathbf{y}}_i, \mathbf{y}_i)$ ;
14     反向传播:  $\theta \leftarrow \theta - \eta_t \cdot \nabla_{\theta} \mathcal{L}$ ;
15     更新学习率: 通过 CosineAnnealingLR 更新  $\eta_t$ ;
16     if  $t \bmod 10 = 0$  then
17         保存 checkpoint:  $f_{\theta}^{(t)}$ ;

```

3 实验设置

3.1 数据集

本研究使用 Kaggle 平台公开的 Chest CT Segmentation 数据集², 包含胸部 CT 横断面图像及对应的三器官分割掩码。数据集统计信息如表 5 所示。

²<https://www.kaggle.com/datasets/polomarco/chest-ct-segmentation>

表 5. 数据集统计信息

项	描述
图像-掩码对总数	1,000
训练集	800 (80 %)
验证集	200 (20 %)
图像格式	JPG, 512×512
掩码格式	JPG (RGB), 阈值 ≥ 240
分割类别	肺 (R 通道)、心脏 (G 通道)、气管 (B 通道)
配对关系	train.csv: ImageId $\leftrightarrow$ MaskId

掩码为 RGB 三通道图像, 像素值 ≥ 240 的区域为有效分割区域。原始数据集通道顺序为 BGR (OpenCV 格式), 训练与测试代码中通过通道交换操作 `labels[:, [2,1,0], :, :]` 将其转换为 RGB 顺序, 对应 [肺、心脏、气管]。

3.2 环境配置

本实验的硬件与软件环境如表 6 所示。

表 6. 实验环境配置

类别	配置
操作系统	Linux
GPU	NVIDIA CUDA (cuda:1)
PyTorch	≥ 2.0
MONAI	$\geq 1.5.2$
其他依赖	Pandas, NumPy, scikit-learn, Matplotlib, tqdm

3.2.1 训练配置

表 7 汇总了两种架构的完整训练配置。

表 7. 训练配置对比

超参数	Swin-UNETR v2 (实验一、二)	UNet++ (实验三)
优化器	AdamW [12]	AdamW [12]
学习率 $\eta_{\max}$	1×10^{-4}	1×10^{-4}
权重衰减	1×10^{-5}	1×10^{-5}
学习率调度	CosineAnnealingLR	CosineAnnealingLR
$T_{\max}$	200	150
$\eta_{\min}$	10^{-6}	10^{-6}
损失函数	DiceFocalLoss	DiceFocalLoss
$\lambda_{\text{Dice}} = \lambda_{\text{Focal}}$	1.0	1.0
批大小	16	64
训练轮数	200	150
数据划分	80 % 训练 / 20 % 验证	80 % 训练 / 20 % 验证
随机种子	520	520
检查点间隔	每 10 个 epoch 保存一次	每 10 个 epoch 保存一次
数据增强	重增强 (含旋转 90°、噪声、对比度)	轻增强 (仅翻转、仿射)

两种架构共享相同的优化器 (AdamW)、损失函数 (DiceFocalLoss) 和学习率调度策略 (CosineAnnealingLR)，以确保对比的公平性。关键差异在于批大小与训练轮数：UNet++ 采用批大小 64 (Swin-UNETR v2 为 16)，训练 150 轮 (Swin-UNETR v2 为 200 轮)。批大小的选择综合考虑了模型显存占用与梯度估计稳定性，UNet++ 的 EfficientNet-B2 编码器参数效率更高，允许使用更大的批大小。

3.3 实验设计

本研究共设计三组独立实验，以全面评估不同架构与训练策略在胸部 CT 多器官分割任务上的性能。实验配置的确定经历了以下方法学演进过程：

初始探索阶段 (commit 801f54c)：项目初期采用基本的 Swin-UNETR v2 配置进行初步训练，批大小为 64，仅训练 10 轮，未使用数据增强，采用简单的训练/验证划分策略。该阶段的初步结果为后续配置优化提供了方向。

配置优化阶段 (commit 72177c6)：基于初始探索的结果，对训练配置进行了系统性优化：(1) 引入全面的数据增强策略 (RandFlipd、RandAffined、RandGaussianNoised、RandAdjustContrastd、RandRotate90d)，以弥补 Transformer 编码器缺乏局部归纳偏置的不足；(2) 将批大小从 64 降至 16，以提升泛化能力；(3) 引入 CosineAnnealingLR 余弦退火学习率调度器，缓解训练震荡问题；(4) 通过 scikit-learn 的 `train_test_split` 实现规范的训练/验证集划分 (`random_state=520`)。该优化配置构成了实验一与实验二的基础。

基于上述优化配置，本研究设计了以下三组独立实验：

实验一：基于 Swin-UNETR v2 的基准模型实验：首次将 Swin-UNETR v2 架构应用于该数据集，采用优化后的配置进行训练：`feature_size=48`，`use_checkpoint=True`，

use_v2=True, 训练 200 轮, 批大小 16, 随机种子 520, 完整数据增强管道 (RandFlipd、RandAffined、RandGaussianNoised、RandAdjustContrastd、RandRotate90d) 与余弦退火调度。损失函数为 DiceFocalLoss, 优化器为 AdamW (lr=1e-4, weight_decay=1e-5), CosineAnnealingLR ($T_{\max} = 200$, $\eta_{\min} = 1e-6$)。该实验旨在建立 Swin-UNETR v2 在胸部 CT 多器官分割任务上的基线性能, 最优 mDSC 为 0.9388 (第 180 轮)。

实验二: Swin-UNETR v2 参数优化实验: 采用与实验一完全相同的 Swin-UNETR v2 架构与超参数配置, 训练 200 轮, 批大小 16, 随机种子 520。该实验旨在验证优化配置的可复现性与稳定性, 确认 Swin-UNETR v2 在相同配置下能否稳定收敛至相近的性能水平。实验二取得了略优于实验一的结果, 最优 mDSC 为 0.9390 (第 190 轮), 且训练后期收敛更为稳定 (第 200 轮未出现显著的 DSC 下降)。

实验三: 基于预训练 UNet++ 的对比实验: 采用 UNet++ (EfficientNet-B2 编码器, ImageNet 预训练权重) 架构, 训练 150 轮, 批大小 64, 随机种子 520, 轻量数据增强策略 (仅 RandFlipd 与 RandAffined, 概率降至 0.3, 变换范围缩小)。损失函数与优化器同实验一、二 (DiceFocalLoss、AdamW), CosineAnnealingLR ($T_{\max} = 150$, $\eta_{\min} = 1e-6$)。该实验旨在通过对比不同架构的性能, 评估 CNN 预训练编码器与嵌套跳跃路径设计相对于 Transformer 架构在分割精度上的差异, 最优 mDSC 为 0.9661 (第 150 轮)。

实验一与实验二构成 Swin-UNETR v2 的参数优化验证组, 实验三构成架构对比组。三组独立实验共享相同的数据集划分、损失函数与优化器配置, 确保对比的公平性与结论的可靠性。此外, 第 2.4 节所述的 Kaggle 开源参考基线 (U-Net + BCEDiceLoss + Adam) 提供了额外的性能参照。

3.4 评价指标

本研究采用以下指标评估分割性能:

Dice 相似系数 (Dice Similarity Coefficient, DSC): 衡量预测与真实分割的重叠程度, 取值范围为 $[0, 1]$, 值越大表示分割效果越好:

$$\text{Dice} = \frac{2|A \cap B|}{|A| + |B|} \quad (9)$$

其中 A 为预测分割区域, B 为真实标注区域。

交并比 (Intersection over Union, IoU): 又称 Jaccard 系数, 衡量预测与真实分割的交并比:

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (10)$$

平均 Dice/平均 IoU (mDSC/mIoU): 所有类别 Dice/IoU 的算术平均值, 用于综合评估多类别分割性能。

4 实验结果与分析

如第 3.3 节所述，本研究共进行三组独立实验：实验一与实验二采用 Swin-UNETR v2 架构（相同配置，验证参数优化的可复现性），实验三采用 UNet++ 架构（架构对比）。本节依次展示各实验的定量结果、训练动态与对比分析。

4.1 定量结果

4.1.1 实验一：基于 Swin-UNETR v2 的基准模型结果

表 8 展示了实验一在关键训练轮次的定量评估结果。

表 8. 关键训练轮次的定量评估结果（实验一：Swin-UNETR v2 基准模型）

轮次	DSC _肺	DSC _{心脏}	DSC _{气管}	mDSC
10	0.8308	0.8785	0.6852	0.7982
20	0.8766	0.9114	0.8306	0.8729
50	0.8895	0.9009	0.8722	0.8876
100	0.9065	0.8978	0.9327	0.9124
140	0.9372	0.8956	0.9436	0.9255
170	0.9612	0.9043	0.9458	0.9371
180	0.9632	0.9132	0.9398	0.9388
200	0.9622	0.8433	0.9148	0.9068

实验一的最优模型出现在第 180 轮，mDSC 达 0.9388。值得注意的是，第 200 轮时心脏 DSC 出现显著下降（从 0.9132 降至 0.8433），导致 mDSC 降至 0.9068，表明 Swin-UNETR v2 在训练后期存在过拟合风险。

4.1.2 实验二：Swin-UNETR v2 参数优化实验结果

表 9 展示了实验二在关键训练轮次的定量评估结果，该实验取得了 Swin-UNETR v2 两组实验中的最佳性能。

表 9. 关键训练轮次的定量评估结果（实验二：Swin-UNETR v2 参数优化）

轮次	DSC _肺	IoU _肺	DSC _{心脏}	IoU _{心脏}	DSC _{气管}	IoU _{气管}	mDSC	mIoU
10	0.8148	0.7888	0.6385	0.6202	0.5224	0.4873	0.6586	0.6321
20	0.8512	0.8275	0.8094	0.7924	0.6139	0.5822	0.7581	0.7340
50	0.8313	0.8057	0.7383	0.7209	0.8629	0.8331	0.8109	0.7865
100	0.9113	0.8905	0.8351	0.8199	0.9225	0.8959	0.8896	0.8688
150	0.9621	0.9420	0.8936	0.8799	0.9412	0.9183	0.9323	0.9134
170	0.9650	0.9461	0.8958	0.8823	0.9449	0.9231	0.9352	0.9172
180	0.9652	0.9464	0.9018	0.8883	0.9451	0.9234	0.9374	0.9194
190	0.9660	0.9475	0.9054	0.8920	0.9458	0.9243	0.9390	0.9212
200	0.9664	0.9480	0.8995	0.8860	0.9455	0.9242	0.9371	0.9194

实验二的最优模型出现在第 190 轮，mDSC 达 0.9390。与实验一相比，实验二在训练后期（第 200 轮）的性能下降幅度较小（mDSC 从 0.9390 降至 0.9371），表现出更稳定的收敛特性。

4.1.3 实验三：基于预训练 UNet++ 的对比实验结果

表 10 展示了实验三在关键训练轮次的定量评估结果。

表 10. 关键训练轮次的定量评估结果（实验三：预训练 UNet++）

轮次	DSC _肺	DSC _{心脏}	DSC _{气管}	mDSC
10	0.8846	0.8765	0.7427	0.8346
20	0.9366	0.8694	0.8520	0.8860
50	0.9470	0.9173	0.9008	0.9217
60	0.9568	0.9617	0.9319	0.9501
100	0.9689	0.9701	0.9505	0.9632
120	0.9695	0.9703	0.9544	0.9647
140	0.9703	0.9712	0.9560	0.9658
150	0.9702	0.9718	0.9563	0.9661

实验三的最优模型出现在第 150 轮（最后一个训练轮次），mDSC 达 0.9661，显著优于 Swin-UNETR v2 的两组实验。值得注意的是，UNet++ 仅用 10 轮训练即达到 mDSC 0.8346，已接近 Swin-UNETR v2 训练 50 轮的水平，充分体现了预训练编码器的优势。此外，UNet++ 在训练过程中未出现性能下降现象，模型在整个训练周期内保持稳定提升。

4.1.4 最佳性能对比

表 11 汇总了三组独立实验的最佳性能结果。

表 11. 三组独立实验最佳性能对比

指标	Exp-I Swin-UNETR v2	Exp-II Swin-UNETR v2	Exp-III UNet++	整体最佳
DSC _肺	0.9632	0.9660	0.9702	0.9702
DSC _{心脏}	0.9132	0.9054	0.9718	0.9718
DSC _{气管}	0.9398	0.9458	0.9563	0.9563
mDSC	0.9388	0.9390	0.9661	0.9661
最佳轮次	180	190	150	-

从表中可以得出以下关键发现：（1）UNet++ 在所有器官类别上均显著优于 Swin-UNETR v2，mDSC 提升 2.71 个百分点；（2）UNet++ 的心脏分割性能提升最为显著（DSC 从 0.9132 提升至 0.9718，提升 5.86 个百分点），表明预训练编码器对心脏这类边界模糊器

官的分割具有明显优势；(3) 实验一与实验二的 Swin-UNETR v2 结果非常接近 (mDSC 差异仅 0.0002)，验证了优化配置的良好可复现性。

为进一步对比各配置的全面差异，表 12 汇总了参考基线与三组实验的完整配置与性能。

表 12. 参考基线与三组实验的配置及性能对比

配置项	参考基线	实验一	实验二	实验三
模型	U-Net	Swin-UNETR v2	Swin-UNETR v2	UNet++
编码器	EfficientNet-B2	Swin Transformer	Swin Transformer	EfficientNet-B2
编码器预训练	ImageNet	无	无	ImageNet
损失函数	BCEDiceLoss	DiceFocalLoss	DiceFocalLoss	DiceFocalLoss
优化器	Adam	AdamW	AdamW	AdamW
学习率	8e-5	1e-4	1e-4	1e-4
学习率调度	ReduceLROnPlateau	CosineAnnealingLR	CosineAnnealingLR	CosineAnnealingLR
批大小	8	16	16	64
训练轮数	100+1	200	200	150
数据增强	仅 VerticalFlip	重增强	重增强	轻增强
随机种子	555	520	520	520
数据划分	random_state=69	random_state=520	random_state=520	random_state=520
Best mDSC	0.968*	0.9388	0.9390	0.9661

* 注：参考基线使用不同的数据划分 (random_state=69)，其 mDSC 与本研究实验不可直接比较。

4.2 训练动态

4.2.1 损失收敛分析

图 2 展示了三组独立实验的训练损失变化趋势。




图 2. 三组独立实验的训练损失曲线。(a)(b) Swin-UNETR v2 呈现两阶段收敛特征, 损失从 ~ 0.9 降至 ~ 0.30 ; (c) UNet++ 在第 50-60 轮间出现急剧下降 (从 0.55 降至 0.07), 最终收敛至 0.034, 远低于 Swin-UNETR v2。

三组独立实验的损失曲线呈现出截然不同的收敛特征:

Swin-UNETR v2 (Exp-I、Exp-II): 损失曲线呈现两阶段收敛特征。第一阶段 (第 1-125 轮) 损失快速下降, 从初始的 ~ 0.9 降至 ~ 0.38 ; 第二阶段 (第 126-200 轮) 损失在较低水平缓慢收敛, 最终稳定在 0.30 左右。实验一在第 162 轮附近出现一次显著的损失跳变

(从 0.38 降至 0.32)，可能归因于余弦退火调度器在训练中期学习率仍较大时，模型参数跨越损失曲面鞍点所致。

UNet++ (Exp-III): 损失曲线呈现出更为独特的三阶段收敛特征。第一阶段（第 1-50 轮）损失缓慢下降，从 0.96 降至 0.55，与 Swin-UNETR v2 的收敛速度相近；第二阶段（第 51-60 轮）损失急剧下降，从 0.44 骤降至 0.07，这一突变可能与预训练编码器的特征激活有关——当学习率降至特定阈值时，预训练特征与任务特定特征实现有效对齐，导致损失骤降；第三阶段（第 60-150 轮）损失在极低水平缓慢收敛，最终稳定在 0.034 左右，远低于 Swin-UNETR v2 的 0.30，表明 UNet++ 在训练集上实现了更充分的拟合。

4.2.2 各器官 Dice 系数变化趋势

图 3 展示了三组独立实验中各器官 Dice 系数随训练轮次的变化趋势。




图 3. 三组独立实验各器官 Dice 系数变化趋势。(a)(b) Swin-UNETR v2 中肺收敛最快，心脏与气管后期波动明显；(c) UNet++ 中三类器官均在第 60 轮后快速收敛至 0.95 以上，心脏 DSC 甚至超过肺，展现出优异的分割性能。

从图中可以观察到以下规律：

Swin-UNETR v2 (Exp-I、Exp-II)：肺 DSC 在训练早期即快速上升至 0.90 以上，后期稳定在 0.96 附近；心脏 DSC 上升较为缓慢，在第 130 轮后趋于 0.90，但实验一在第 200 轮出现显著下降 (0.8433)，表明存在过拟合风险；气管 DSC 在训练初期波动较大，最

终稳定在 0.94 左右。

UNet++ (Exp-III): 三类器官的 DSC 均在第 60 轮后快速上升至 0.95 以上，展现出极为高效的收敛特性。特别值得注意的是，心脏 DSC 在第 60 轮出现跳变（从 0.9173 升至 0.9617），与损失曲线的骤降点吻合，此后持续稳定提升至 0.9718。UNet++ 中心脏 DSC 甚至超过了肺 DSC，这在 Swin-UNETR v2 的实验中从未观察到，表明预训练编码器对心脏分割的提升尤为显著。

4.2.3 各实验最佳模型性能对比

图 4 以柱状图形式直观对比了三组独立实验最优模型在各器官上的 DSC。




图 4. 三组独立实验最佳模型各器官 DSC 对比。UNet++ 在所有器官上均优于 Swin-UNETR v2，心脏分割提升最为显著（+5.86pp）。

4.3 Swin-UNETR v2 与 UNet++ 对比分析

基于上述实验结果，本节从多个维度对两种架构进行系统对比分析。

4.3.1 分割精度对比

UNet++ 在所有器官类别上均显著优于 Swin-UNETR v2。表 13 量化了 UNet++ 相对于 Swin-UNETR v2 最佳结果的性能提升。

表 13. UNet++ 相对于 Swin-UNETR v2 的性能提升

器官	Swin-UNETR v2 最佳	UNet++ 最佳	提升
肺	0.9660	0.9702	+0.42pp
心脏	0.9132	0.9718	+5.86pp
气管	0.9458	0.9563	+1.05pp
mDSC	0.9390	0.9661	+2.71pp

心脏分割的性能提升最为显著 (+5.86pp)，这一结果可从以下角度理解：心脏与周围纵隔组织的灰度差异较小，边界模糊，对特征提取的质量要求更高。Swin-UNETR v2 从头训练的 Transformer 编码器需要大量数据来学习有效的边界特征，而 UNet++ 的预训练 EfficientNet-B2 编码器已具备丰富的边缘与纹理特征提取能力，能够更精确地定位心脏边界。

4.3.2 收敛速度对比

两种架构的收敛速度存在显著差异。以 mDSC 达到 0.90 为基准：Swin-UNETR v2 需要约 100 轮训练（实验二第 100 轮 mDSC=0.8896），而 UNet++ 仅用约 20 轮即达到 mDSC=0.8860，在第 60 轮已达到 mDSC=0.9501。UNet++ 的收敛速度约为 Swin-UNETR v2 的 5 倍，这主要归功于预训练编码器提供的良好特征初始化。

此外，UNet++ 的训练过程更为稳定，未出现 Swin-UNETR v2 中观察到的后期性能下降现象。Swin-UNETR v2 实验一在第 200 轮出现心脏 DSC 骤降 (0.9132→0.8433)，而 UNet++ 在整个训练周期内各器官 DSC 均保持单调递增或稳定，表现出更优的训练稳定性。

4.3.3 训练效率对比

从训练效率角度，UNet++ 仅需 150 轮训练即达到 mDSC=0.9661，而 Swin-UNETR v2 需要 200 轮训练仅达到 mDSC=0.9390。结合批大小差异（UNet++ 批大小 64 vs Swin-UNETR v2 批大小 16），UNet++ 在每个 epoch 中处理更多的样本梯度，进一步加速了有效收敛。

4.4 定性可视化

图 5 展示了典型样本的分割效果可视化。实验三 (Exp-III) 的 UNet++ 模型在肺、心脏和气管三类器官上均取得了视觉上令人满意的分割结果，预测掩码与真实掩码高度吻合。




图 5. 分割可视化结果。(a) 真实标注，彩色掩码叠加于 CT 图像；(b) 模型预测，三类器官均与真实标注高度重叠。青色表示肺部，红色表示心脏，黄色表示气管。

从可视化结果可以看出：(1) 肺部区域分割完整，左右肺叶均被准确识别；(2) 心脏区域边界清晰，与周围纵隔组织区分明显；(3) 气管结构被精确分割，即使在狭窄部位也保持良好的连续性。这表明 UNet++ 模型能够有效捕获胸部 CT 图像中不同器官的形态特征，实现高精度的多器官分割。

5 讨论

5.1 Swin-UNETR v2 与 UNet++ 的对比分析

本研究的实验结果清晰地表明，UNet++（EfficientNet-B2 编码器）在胸部 CT 多器官分割任务上全面优于 Swin-UNETR v2。这一性能差异可从以下维度进行深入分析：

1. 预训练编码器的关键作用。Swin-UNETR v2 的 Swin Transformer 编码器从头训练，缺乏先验特征知识，需要通过大量训练数据与训练轮次来学习视觉特征。相比之下，UNet++ 的 EfficientNet-B2 编码器加载了 ImageNet 预训练权重，尽管 ImageNet 与医学 CT 图像的领域差异较大，但预训练权重仍提供了有价值的低层特征（如边缘、纹理检测）和中层特征（如形状组合），这些特征经微调后可有效地迁移至 CT 分割任务。这一发现与医学图像分割领域的已有研究一致：在有限数据集上，预训练编码器通常优于从头训练的编码器。

2. 归纳偏置的影响。卷积神经网络的局部归纳偏置（局部连接、权值共享、平移等变性）天然适合图像处理任务，尤其是对局部纹理与边界特征的提取。Swin Transformer 虽然通过移位窗口机制实现了全局建模能力，但其弱归纳偏置意味着模型需要更多数据来学习这些局部特征。在仅 800 张训练图像的有限数据条件下，卷积架构的归纳偏置优势更为突出。

3. 嵌套跳跃路径的语义桥接效应。UNet++ 的嵌套跳跃连接通过逐步缩小编码器与解码器特征之间的语义差距，使传递至解码器的特征更具语义一致性。相比之下，Swin-UNETR v2 采用传统的直接跳跃连接，编码器浅层特征（低级纹理）与解码器深层特征（高级语义）之间的语义鸿沟可能影响分割边界的精确性。

4. **批大小与数据增强的交互效应。**UNet++ 采用批大小 64 (Swin-UNETR v2 为 16), 更大的批大小提供了更稳定的梯度估计, 有助于模型在预训练权重的良好初始化附近进行高效优化。同时, UNet++ 采用了更轻量的数据增强策略, 避免了过度增强对预训练特征的破坏。这一组合 (大批大小 + 轻增强 + 预训练权重) 在有限数据集上表现出了优异的效果。

5. **收敛稳定性的差异。**Swin-UNETR v2 在训练后期出现了性能下降现象 (实验一第 200 轮心脏 DSC 骤降), 表明 Transformer 架构在长训练周期中存在过拟合风险。UNet++ 在整个训练过程中保持稳定提升, 未出现性能回退, 这得益于预训练权重的正则化效应与更大批大小带来的梯度稳定性。

5.2 器官分割难度分析

综合三组独立实验的结果, 器官分割难度呈现以下规律:

肺: 在两种架构中均最易分割, DSC 稳定在 0.96 以上。肺组织在 CT 图像中占比最大 (约占图像面积的 30-40%) 且对比度高 (含气组织与周围软组织灰度差异显著), 这些有利条件使得即使较简单的模型也能取得良好的分割效果。

气管: 气管像素占比最小 (<5%), 但得益于 DiceFocalLoss 对难分类样本的聚焦效应, 两种架构均取得了较好的分割效果。Swin-UNETR v2 的气管 DSC 为 0.9458, UNet++ 为 0.9563, 提升幅度 (+1.05pp) 相对较小, 表明 DiceFocalLoss 已有效缓解了气管的类别不平衡问题。

心脏: 心脏是两种架构性能差异最大的器官 (Swin-UNETR v2 最佳 0.9132 vs UNet++ 0.9718, 提升 5.86pp)。心脏分割困难的原因在于: (1) 心脏与周围纵隔组织的灰度差异较小, 边界模糊; (2) 心脏形态存在较大的个体差异; (3) 心脏区域的灰度值与背景较为接近。UNet++ 的预训练编码器提供了更精确的边界特征提取能力, 嵌套跳跃连接改善了边界处的特征融合效果, 这两者共同促成了心脏分割性能的显著提升。

5.3 损失函数的有效性

DiceFocalLoss 在两种架构中均展现了良好的效果。Dice 部分直接优化分割重叠度, 对类别不平衡具有天然鲁棒性; Focal 部分通过降低易分类样本的损失权重, 使模型聚焦于难分类区域 (如器官边界与小器官)。两者结合有效缓解了类别不平衡问题, 使得气管这类小器官的 DSC 能够达到 0.94 以上。

5.4 局限性分析

本研究存在以下局限性:

1. **数据集规模有限**：本实验使用的 Kaggle 数据集仅有 1,000 对图像-掩码对，与医学图像分割领域常用的大规模数据集相比规模较小。更大规模、多中心的数据集将有助于进一步验证两种架构的性能差异，特别是 Swin-UNETR v2 在更大数据集上是否能够缩小与 UNet++ 的差距。

2. **仅为 2D 分割**：本研究采用的是 2D 分割方法，没有利用 CT 层间的连续性信息。3D 分割方法可能能够利用更多的上下文信息，进一步提升分割精度。

3. **对比实验的变量控制**：实验三（UNet++）与实验一、二（Swin-UNETR v2）在批大小、训练轮数和数据增强策略上存在差异，这些混淆变量可能影响架构对比的结论。理想的对比实验应仅改变架构本身，控制其他变量不变。然而，不同架构的最优训练配置本身存在差异，完全控制变量可能无法反映各架构的实际潜力。

4. **缺乏更多方法的对比**：本研究仅对比了 Swin-UNETR v2 与 UNet++ 两种架构，未涉及 TransUNet、nnU-Net 等其他前沿方法，无法全面评估本方法在领域内的相对优势。

5.5 未来工作展望

基于本研究的结果和局限性，未来可以从以下方向进行探索：

1. **Swin-UNETR v2 的预训练策略**：探索为 Swin Transformer 编码器引入自监督预训练（如 Masked Image Modeling），以弥补其缺乏预训练权重的不足，评估预训练对 Swin-UNETR v2 性能的提升幅度。

2. **3D 分割方法**：将 2D 分割方法扩展为 3D 版本，充分利用 CT 图像的层间信息，探索 3D 上下文对分割性能的提升潜力。

3. **混合架构设计**：结合 Transformer 的全局建模能力与 CNN 的局部特征提取优势，设计混合编码器架构，如 CNN 提取局部特征后接 Transformer 建模全局依赖。

4. **模型轻量化与部署**：通过知识蒸馏、剪枝、量化等技术压缩模型，使其能够在资源受限的环境中部署。

5. **跨数据集泛化能力验证**：在多个公开数据集上评估本方法的性能，并探索域适应技术，提升模型在不同来源数据上的泛化能力。

6 结论

本研究针对胸部 CT 图像的多器官分割任务，系统比较了 Swin-UNETR v2 与 UNet++ (EfficientNet-B2 编码器) 两种架构的性能。在 Kaggle Chest CT Segmentation 数据集上进行了三组独立实验：实验一与实验二采用 Swin-UNETR v2（相同配置，验证参数优化的可复现性），实验三采用 UNet++（架构对比）。此外，以 Kaggle 开源示例（U-Net + BCEDiceLoss + Adam, val_dice=0.968）作为参考基线。

实验结果表明：(1) Swin-UNETR v2 的实验一与实验二最佳 mDSC 分别为 0.9388 与 0.9390，差异仅 0.02%，验证了优化配置的良好可复现性；(2) UNet++ 取得了 0.9661 的 mDSC，显著优于 Swin-UNETR v2，其中肺、心脏、气管的 DSC 分别为 0.9702、0.9718 和 0.9563；(3) UNet++ 的收敛速度约为 Swin-UNETR v2 的 5 倍，且训练过程更为稳定，未出现后期性能下降现象；(4) 参考基线 (U-Net + EfficientNet-B2 + BCEDiceLoss) 在不同数据划分上取得了 $\text{val_dice}=0.968$ ，与实验三的 UNet++ 性能相近，但两者使用了不同的数据划分、损失函数和优化器，不宜直接比较。

性能差异的核心原因在于：预训练编码器提供了良好的特征初始化，卷积架构的局部归纳偏置更适合有限数据条件下的医学图像分割，嵌套跳跃连接有效改善了边界处的特征融合。这些发现为胸部 CT 分割任务的架构选择提供了重要参考：在训练数据有限的场景下，采用预训练编码器的 CNN 架构可能比从头训练的 Transformer 架构更为高效。

本研究的贡献包括：(1) 系统比较了 Transformer 与 CNN 预训练编码器架构在胸部 CT 分割任务上的性能差异；(2) 揭示了预训练编码器、归纳偏置与数据增强策略对分割性能的交互影响；(3) 提供了完整的实验流程和结果分析，为该领域的后续研究提供了可复现的参考。

尽管本研究取得了良好的结果，但仍存在数据集规模有限、对比实验变量控制不够严格等局限性。未来可以从自监督预训练、3D 分割、混合架构设计等方向进一步探索，提升方法的性能和实用性。

参考文献

- [1] A. Hatamizadeh et al. "Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images". In: *Int. Conf. Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2022, pp. 272–282.
- [2] O. Ronneberger, P. Fischer, and T. Brox. "U-Net: Convolutional Networks for Biomedical Image Segmentation". In: *Int. Conf. Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2015, pp. 234–241.
- [3] F. Isensee et al. "nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation". In: *Nature Methods* 18.2 (2021), pp. 203–211.
- [4] J. Chen et al. "TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation". In: *arXiv preprint arXiv:2102.04306* (2021).
- [5] H. Wang et al. "UCTransNet: Rethinking the Skip Connections in U-Net from a Channel-wise Perspective with Transformer". In: *AAAI Conf. Artificial Intelligence*. 2022.

- [6] Z. Liu et al. “Swin Transformer: Hierarchical Vision Transformer using Shifted Windows”. In: *IEEE/CVF Int. Conf. Computer Vision (ICCV)*. 2021, pp. 10012–10022.
- [7] Z. Zhou et al. “UNet++: A Nested U-Net Architecture for Medical Image Segmentation”. In: *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (DLMIA)*. Springer, 2018, pp. 3–11.
- [8] M. Tan and Q. V. Le. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. In: *Int. Conf. Machine Learning (ICML)*. 2019.
- [9] M. J. Cardoso et al. “MONAI: An open-source framework for deep learning in healthcare”. In: *arXiv preprint arXiv:2211.02701* (2022).
- [10] F. Milletari, N. Navab, and S.-A. Ahmadi. “V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation”. In: *Int. Conf. 3D Vision (3DV)*. 2016, pp. 565–571.
- [11] T.-Y. Lin et al. “Focal Loss for Dense Object Detection”. In: *IEEE Int. Conf. Computer Vision (ICCV)*. 2017, pp. 2980–2988.
- [12] I. Loshchilov and F. Hutter. “Decoupled Weight Decay Regularization”. In: *arXiv preprint arXiv:1711.05101* (2017).