

《医学图像处理技术》 期末项目报告

题目：任务二 Chest CT Segmentation

组号：15

小组成员姓名：俞烨，张天硕，张璟文，张鸿榜，
吴君凯，黄绍华，陈飞翔，刘华胜

小组成员学号：102301116, 102301113, 102301114, 102301115,
102301121, 102301137, 102301142, 022304111

评分：

1、语言与排版（25 分）：_____

2、问题难易程度（25 分）：_____

3、实践掌握程度（50 分）：_____

总分：_____

人员分工表

表 1. 小组成员分工明细

序号	姓名	具体分工内容
1	俞烨（组长）	总体实验方案设计与技术路线规划；Swin-UNETR v2 架构核心代码实现与调试；DiceFocalLoss 复合损失函数设计与集成；训练流程框架搭建；实验统筹协调与进度管理；论文整体架构设计与终稿审定
2	吴君凯	Swin-UNETR v2 基准与扩展长时实验执行与训练记录；完整数据增强管线实现；训练超参数初步探索与调优；实验日志维护与 Checkpoint 管理
3	刘华胜	Swin-UNETR v2 参数优化实验执行与记录；实验环境配置与 GPU 资源管理批大小与学习率调度策略对比分析；训练过程 Loss 曲线与指标变化可视化；部分实验结果图表绘制
4	黄绍华	UNet++ 对比实验执行与记录；预训练编码器集成；轻量数据增强策略设计与验证；架构对比分析数据整理与汇总
5	张璟文	参考基线 U-Net 复现；基线对比实验数据整理；评估指标计算与汇总
6	张鸿榜	数据集预处理；数据集划分与统计分析；数据质量检查
7	陈飞翔	报告主体内容撰写；文献调研与参考文献整理；PPT 整体框架设计与制作；技术图表绘制
8	张天硕	报告实验结果与分析部分撰写；讨论与结论部分撰写；报告格式排版与校对；PPT 内容补充与美化

Abstract: This study systematically investigates the performance of Transformer-based and CNN-based architectures for multi-organ segmentation of chest CT images on the Kaggle Chest CT Segmentation dataset. Two architectures are compared: Swin-UNETR v2, which employs a hierarchical Swin Transformer encoder with shifted-window self-attention, and UNet++ with a pretrained EfficientNet-B2 encoder and nested skip pathways. Four experiments are conducted using DiceFocalLoss, AdamW optimization, and cosine annealing scheduling: two 200-epoch Swin-UNETR v2 runs, a 150-epoch UNet++ run, and a 500-epoch extended Swin-UNETR v2 run. A fair comparison baseline is established using the same U-Net architecture with identical preprocessing (mDice=0.9031). The UNet++ model achieves the highest mDSC of 0.9661, while the extended Swin-UNETR v2 training yields mDSC=0.9655, demonstrating that the Transformer architecture can match CNN performance given sufficient training time. All experimental methods substantially outperform the fair baseline. These findings provide practical guidance for architecture selection and training strategy design in medical image segmentation.

Keywords: Chest CT, Multi-organ Segmentation, Swin-UNETR, UNet++,
DiceFocalLoss

摘要：本研究在 Kaggle Chest CT Segmentation 数据集上系统比较了 Transformer 与 CNN 两种架构范式的胸部 CT 多器官分割性能。采用 Swin-UNETR v2 (移位窗口 Transformer 编码器) 与 UNet++ (预训练 EfficientNet-B2 编码器 + 嵌套跳跃路径) 两种架构, 基于 DiceFocalLoss、AdamW 优化器与余弦退火调度策略, 进行了四组实验: 两组 200 轮 Swin-UNETR v2、一组 150 轮 UNet++ 及一组 500 轮扩展训练 Swin-UNETR v2。以相同预处理条件下的 U-Net 基线 ($mDice=0.9031$) 作为公平对比参照。UNet++ 取得最高 mDSC (0.9661), 扩展训练的 Swin-UNETR v2 达到 0.9655, 表明 Transformer 架构在充分训练条件下可达到与 CNN 相当的性能。所有实验方法均大幅优于公平对比基线。上述发现为医学图像分割中的架构选择与训练策略设计提供了实践指导。

关键词：胸部 CT; 多器官分割; Swin-UNETR; UNet++; DiceFocalLoss

目录

1	引言	3
1.1	主要贡献	3
1.2	报告结构	4
2	研究方法	4
2.1	参考基线	4
2.1.1	简单预处理基线	4
2.1.2	硬预处理基线	5
2.1.3	训练配置	5
2.1.4	与本研究实验的关键差异	5
2.1.5	U-Net 架构详解	6
2.1.6	前向传播流程	7
2.2	Swin-UNETR v2 架构	7
2.2.1	Patch Partition 与线性嵌入	8
2.2.2	Swin Transformer 编码器	8
2.2.3	CNN 解码器	9
2.2.4	前向传播流程	9
2.2.5	窗口自注意力计算	10
2.2.6	网络配置	11
2.3	基于 UNet++ 的对比模型	12
2.3.1	架构设计原理	12
2.3.2	EfficientNet-B2 编码器	13
2.3.3	嵌套跳跃路径解码器	13
2.3.4	前向传播流程	13
2.3.5	网络配置	14
2.3.6	与 U-Net 的关键差异	15
2.4	架构对比	15
2.5	数据预处理	16
2.6	损失函数	17
2.6.1	损失函数计算流程	17
2.7	优化与训练	18
3	实验设置	19
3.1	数据集	19

3.2	环境配置	20
3.2.1	训练配置	20
3.3	实验设计	21
3.4	评价指标	22
4	实验结果与分析	23
4.1	定量结果	23
4.1.1	参考基线结果	23
4.1.2	基于 Swin-UNETR v2 的基准实验关键轮次结果	24
4.1.3	基于 Swin-UNETR v2 的参数优化实验关键轮次结果	24
4.1.4	基于 UNet++ 的对比实验关键轮次结果	25
4.1.5	基于 Swin-UNETR v2 的扩展训练实验关键轮次结果	25
4.1.6	最佳性能对比	26
4.2	训练动态	26
4.2.1	损失收敛分析	26
4.2.2	各器官 Dice 系数变化趋势	28
4.2.3	各实验最佳模型性能对比	30
4.3	Swin-UNETR v2 与 UNet++ 对比分析	31
4.3.1	分割精度对比	31
4.3.2	收敛速度对比	31
4.3.3	训练效率对比	31
4.4	定性可视化	32
5	讨论	33
5.1	Swin-UNETR v2 与 UNet++ 的对比分析	33
5.2	与参考基线的对比分析	34
5.3	器官分割难度分析	35
5.4	损失函数的有效性	35
5.5	局限性分析	35
5.6	未来工作展望	36
6	结论	36
	参考文献	37

1 引言

胸部计算机断层扫描 (Computed Tomography, CT) 是临床胸部疾病诊断最常用的影像学检查手段, 其高分辨率横断面成像能够清晰显示肺部、心脏及气道等关键解剖结构 [1]。精确的器官分割是后续定量分析与计算机辅助诊断 (Computer-Aided Diagnosis, CAD) 系统的基础, 在肺部疾病诊断——包括肺结节检测、肺气肿量化与肺炎范围评估——心脏功能评估——包括心室体积测量与心壁厚度分析——气道病变分析——包括气管狭窄与支气管扩张评估——以及胸部手术规划与导航等场景中具有重要应用价值。

近年来, 深度学习技术在医学影像分割领域取得了突破性进展。Ronneberger 等人 [2] 提出的 U-Net 架构凭借编码器-解码器结构与跳跃连接, 成为医学图像分割的里程碑方法。Isensee 等人 [3] 提出的 nnU-Net 通过自适应配置策略进一步提升了分割性能。然而, 基于卷积神经网络 (CNN) 的方法受限于局部感受野, 难以建模长距离空间依赖关系。

为解决这一局限, Transformer 架构逐渐被引入医学影像分割领域: Chen 等人 [4] 提出 TransUNet, 将 Transformer 编码器与 U-Net 解码器级联; Wang 等人 [5] 提出 UCTransNet, 在跳跃连接中引入通道注意力机制。Liu 等人 [6] 提出的 Swin Transformer 通过局部窗口自注意力与移位窗口机制, 在保持线性计算复杂度的同时实现了高效的全局建模能力。Hatamizadeh 等人 [1] 进一步提出 Swin-UNETR, 将 Swin Transformer 编码器与 U-Net 解码器深度融合, 在多项医学分割基准上取得了领先性能。

尽管上述方法取得了显著进展, 胸部 CT 多器官分割仍面临诸多挑战: 器官形态变异大, 个体间解剖差异显著; 小器官——以气管为代表——像素占比低, 类别不平衡问题突出; 器官边界模糊, 相邻结构灰度差异小; 此外, 不同扫描设备与参数导致的图像质量差异也影响模型泛化能力。

针对上述问题, 本研究以数据集提供方的开源 U-Net 实现为参考基线, 系统比较了 Swin-UNETR v2 与 UNet++ 两种架构在胸部 CT 多器官分割任务上的性能。Swin-UNETR v2 结合 DiceFocalLoss 复合损失函数与余弦退火学习率调度策略, 在 Kaggle Chest CT Segmentation 数据集上实现了肺、心脏和气管三类器官的高精度分割; UNet++ 采用 EfficientNet-B2 预训练编码器与嵌套跳跃路径解码器, 以更轻量的数据增强策略和更大的批大小进行训练, 取得了更优的分割性能。此外, 通过将 Swin-UNETR v2 的训练轮次从 200 扩展至 500, 发现 Transformer 架构在充分训练条件下可以达到与 CNN 预训练编码器架构相当的性能。

1.1 主要贡献

本研究的主要贡献可归纳为以下几个方面。首先, 建立了两种参考基线——简单预处理基线 ($\text{val_dice} \approx 0.974$) 与硬预处理基线 ($\text{mDice} = 0.9031$), 其中后者采用与实验方法相同的 MONAI 预处理流程, 为公平对比提供了可靠的最终基线。其次, 采用 Swin-UNETR v2 架构, 充分发挥 Swin Transformer 的全局建模能力与 U-Net 解码器的精确定位能力; 同时引

入 UNet++ (EfficientNet-B2 编码器) 作为对比模型, 系统比较了 Transformer 架构与 CNN 预训练编码器架构在胸部 CT 分割任务上的性能差异。在训练策略方面, 引入 DiceFocalLoss 复合损失函数以有效缓解类别不平衡问题, 提升小器官 (气管) 的分割性能, 并设计了差异化的数据增强策略与训练配置, 深入分析了批大小、数据增强强度对模型收敛与泛化的影响。通过四组独立实验验证了方法的有效性与参数优化的效果——最优模型 (UNet++) 取得 0.9661 的平均 Dice 系数, 扩展训练的 Swin-UNETR v2 达 0.9655。尤为重要的发现是, Transformer 架构在充分训练条件下 (500 轮) 可达到与 CNN 预训练编码器架构相当的性能, 揭示了训练时长对 Transformer 架构性能的关键影响。此外, 本研究提供了完整的实现代码、训练记录和实验报告, 便于后续研究复现与扩展。

1.2 报告结构

本报告其余部分安排如下: 第 2 节介绍研究方法, 包括参考基线、Swin-UNETR v2 与 UNet++ 两种网络架构、数据预处理、损失函数与训练配置; 第 3 节描述实验设置, 包括数据集、环境配置、评价指标与实验设计; 第 4 节展示实验结果并进行详细分析; 第 5 节讨论两种架构的对比分析、与参考基线的对比、方法局限性与未来工作; 最后第 6 节总结全文。

2 研究方法

2.1 参考基线

为建立性能参考基准, 本研究首先复现了数据集提供方开源的 U-Net 实现(exmample.py) 作为参考基线。该实现采用 segmentation_models_pytorch 库的 U-Net 架构, 以 EfficientNet-B2 [7] 作为编码器, 并加载 ImageNet 预训练权重。与本研究后续实验中使用的 UNet++ 不同, 该基线采用标准 U-Net 解码器, 通过简单的跳跃连接将编码器特征与解码器特征拼接。

本研究建立两种参考基线, 以区分预处理方式对性能的影响:

2.1.1 简单预处理基线

简单预处理基线采用数据集提供方原始的预处理方式, 即 VerticalFlip ($p=0.5$) + ImageNet Normalize, 配合 BCEDiceLoss 与 Adam 优化器, 训练 100 轮。该基线在验证集上取得了 $\text{val_dice} \approx 0.974$ 、 $\text{val_jaccard} \approx 0.958$ 的性能。由于该基线使用了与本研究实验不同的预处理方式和数据划分 ($\text{random_state}=69$), 其结果仅作为参考, 不宜与本研究实验直接对比。

2.1.2 硬预处理基线

为建立公平对比基线，本研究对同一 U-Net (EfficientNet-B2 编码器) 架构使用了与实验方法相同的 MONAI 预处理管线 (ScaleIntensityd、RandFlipd、RandAffined、Resized 等)，并采用相同的 DiceFocalLoss 与 AdamW 优化器。该硬预处理基线在测试集上的结果为：mDice=0.9031, mIoU=0.8835 (肺: 0.9391, 心脏: 0.9509, 气管: 0.8194)。由于使用了与实验方法完全相同的预处理和评价方式，该基线作为本研究实验的最终公平对比基准。

2.1.3 训练配置

两种参考基线的训练配置如表 2 所示。

表 2. 参考基线训练配置

超参数	简单预处理基线	硬预处理基线
架构	U-Net (EfficientNet-B2)	U-Net (EfficientNet-B2)
编码器权重	ImageNet 预训练	ImageNet 预训练
损失函数	BCEDiceLoss	DiceFocalLoss
优化器	Adam ($lr=8 \times 10^{-5}$)	AdamW ($lr=1 \times 10^{-4}$)
学习率调度	ReduceLROnPlateau	CosineAnnealingLR
批大小	8	8
训练轮数	100	1
随机种子	555	520
数据划分	random_state=69	random_state=520
数据增强	VerticalFlip + Normalize	MONAI transforms
框架	albumentations	MONAI

2.1.4 与本研究实验的关键差异

简单预处理基线与本研究后续实验在以下方面存在关键差异：首先，在**架构**方面，基线采用标准 U-Net，而非 Swin-UNETR v2 或 UNet++ 的嵌套跳跃路径设计；其次，在**损失函数**方面，基线采用 BCEDiceLoss (BCE 与 Dice 的加权和)，而非 DiceFocalLoss，后者通过 Focal 机制对难分类样本赋予更高权重；此外，在**优化器与调度器**方面，基线采用 Adam 优化器配合 ReduceLROnPlateau 调度器 (验证指标停滞时降低学习率)，而本研究采用 AdamW 配合 CosineAnnealingLR (周期性余弦退火)；同时，在**数据增强**方面，基线仅使用垂直翻转与归一化，增强策略远轻于 Swin-UNETR v2 的完整增强管线；另外，在**数据划分**方面，基线使用 random_state=69 划分数据，与本研究后续实验的 random_state=520 不同，导致训练/验证集样本构成存在差异；最后，在**框架**方面，基线基于 albumentations 与自定义 Dataset/Trainer 类实现，而本研究基于 MONAI 框架构建。

这些差异使得简单预处理基线与本研究实验之间的直接对比需考虑方法学差异，但基线仍为评估本研究方法的性能水平提供了重要参考。而硬预处理基线通过使用与实验方法

相同的预处理管线、损失函数、优化器和数据划分，消除了上述差异中的 (2) (3) (5) (6) 项，仅保留架构差异，因此可作为公平对比的最终基线。硬预处理基线的 $mDice=0.9031$ 显著低于简单预处理基线的 $val_dice \approx 0.974$ ，表明 MONAI 预处理管线（尤其是 ScaleIntensityd 替代 ImageNet Normalize）对 U-Net 架构的性能产生了较大影响，这进一步凸显了在相同预处理条件下进行对比的必要性。

2.1.5 U-Net 架构详解

参考基线采用的 U-Net 架构 [2] 是医学图像分割领域的经典方法，其核心结构如图 1 所示。U-Net 采用对称的编解码结构，包含四个下采样阶段和四个上采样阶段：




图 1. U-Net 架构示意图。编码器通过最大池化逐步降低空间分辨率并增加特征通道数；解码器通过转置卷积恢复空间分辨率；跳跃连接将编码器特征与解码器特征拼接，保留细节信息。

编码器 (Encoder): 采用卷积层与最大池化交替的结构，每个阶段包含两个 3×3 卷积 (ReLU 激活) 和一个 2×2 最大池化 (步长为 2)。特征通道数从 64 开始逐层翻倍 ($64 \rightarrow 128 \rightarrow 256 \rightarrow 512$)，空间分辨率逐层减半 ($572 \times 572 \rightarrow 286 \times 286 \rightarrow 143 \times 143 \rightarrow 71 \times 71$)。

瓶颈层 (Bottleneck): 编码器最后阶段之后是两个 3×3 卷积层，特征通道数达到 1024，空间分辨率降至 32×32 。

解码器 (Decoder): 采用转置卷积进行上采样，每个阶段包含一个 2×2 转置卷积 (步长为 2) 和两个 3×3 卷积。跳跃连接将编码器对应阶段的特征图裁剪后与解码器上采样特

征拼接，有效融合高层语义信息与低层细节信息。

输出层：最后通过 1×1 卷积将特征映射到目标类别数，产生分割掩码。

参考基线的 U-Net 采用 EfficientNet-B2 作为编码器，而非原始 U-Net 的简单卷积结构。EfficientNet-B2 通过复合缩放策略优化网络深度、宽度和分辨率，在 ImageNet 上预训练后迁移到医学图像分割任务，能够提取更具判别力的特征表示。

2.1.6 前向传播流程

算法 1 描述了 U-Net 的前向传播过程。

Algorithm 1: U-Net 前向传播

Input: 输入图像 $I \in \mathbb{R}^{1 \times H \times W}$
Output: 分割概率图 $\hat{Y} \in \mathbb{R}^{K \times H \times W}$

// 编码阶段

```

1 for  $i \leftarrow 1$  to  $L$  do
2    $e_i \leftarrow \text{ConvBlock}(e_{i-1})$  ; // 两个  $3 \times 3$  卷积 + ReLU
3    $s_i \leftarrow e_i$  ; // 保存跳跃连接特征
4    $e_i \leftarrow \text{MaxPool}_{2 \times 2}(e_i)$  ; // 空间分辨率减半
5  $b \leftarrow \text{ConvBlock}(e_L)$  ; // 瓶颈层
// 解码阶段
6 for  $i \leftarrow L$  to 1 do
7    $d_i \leftarrow \text{ConvTranspose}_{2 \times 2}(d_{i+1})$  ; // 上采样，分辨率翻倍
8    $d_i \leftarrow \text{Concat}(s_i, d_i)$  ; // 跳跃连接拼接
9    $d_i \leftarrow \text{ConvBlock}(d_i)$  ; // 特征融合
10  $\hat{Y} \leftarrow \text{Sigmoid}(\text{Conv}_{1 \times 1}(d_1))$  ; // 输出分割概率

```

其中 ConvBlock 表示两个 3×3 卷积层与 ReLU 激活函数的组合， $L = 4$ 为编码器深度， $K = 3$ 为目标类别数。跳跃连接通过拼接操作将编码器特征 s_i 与解码器特征 d_i 融合，使解码器同时获取高层语义信息与低层空间细节。

2.2 Swin-UNETR v2 架构

本研究采用 Swin-UNETR v2 作为基线分割网络，其整体架构如图 2 所示。该架构创新性地将 Swin Transformer 编码器与 U-Net 风格解码器相结合，既保留了 Transformer 的全局上下文建模能力，又具备 CNN 解码器的精确空间定位能力。




图 2. Swin-UNETR v2 架构示意图。左侧为编码器的四个 Stage，每个 Stage 包含 Swin Transformer Block 和 Patch Merging 操作；右侧展示了 Swin Transformer Block 的内部结构，包含 W-MSA（窗口多头自注意力）和 SW-MSA（移位窗口多头自注意力）两种注意力机制。解码器通过转置卷积上采样并与编码器特征进行跳跃连接融合。

2.2.1 Patch Partition 与线性嵌入

输入图像首先经过 Patch Partition 操作，将 $H \times W \times C$ 的图像划分为 N 个不重叠的 patch ($N = (H \times W)/P^2$ ，其中 P 为 patch 大小)。每个 patch 通过线性投影层转换为固定维度的特征向量，形成初始特征序列：

$$\mathbf{x}_0 = \text{Linear}(\text{flatten}(\text{PatchPartition}(I))) \quad (1)$$

本研究中输入尺寸为 $256 \times 256 \times 1$ ，patch 大小为 4×4 ，因此初始特征维度为 $64 \times 64 \times 48$ 。

2.2.2 Swin Transformer 编码器

Swin Transformer 编码器 [6] 通过层级式特征提取与局部窗口自注意力机制，在保持线性计算复杂度的同时捕获多尺度全局特征。与 ViT [8] 采用全局自注意力不同，Swin Transformer 借鉴了卷积网络的层级设计思想，通过移位窗口机制实现了线性复杂度的注意力计算。如图 2 所示，编码器包含四个 Stage，每个 Stage 由多个 Swin Transformer Block 和一个 Patch Merging 操作组成。

每个 Swin Transformer Block 包含两个连续的注意力模块：

$$\hat{z}^l = \text{W-MSA}(\text{LN}(z^{l-1})) + z^{l-1}, \quad (2)$$

$$z^l = \text{MLP}(\text{LN}(\hat{z}^l)) + \hat{z}^l, \quad (3)$$

$$\hat{z}^{l+1} = \text{SW-MSA}(\text{LN}(z^l)) + z^l, \quad (4)$$

$$z^{l+1} = \text{MLP}(\text{LN}(\hat{z}^{l+1})) + \hat{z}^{l+1}, \quad (5)$$

W-MSA (Window Multi-Head Self-Attention)：在固定大小的局部窗口内计算自注意力，注意力复杂度为 $\mathcal{O}(N \cdot M^2 \cdot C)$ ，其中 M 为窗口大小。当 $M \ll \sqrt{N}$ 时，复杂度近似线性于序列长度。

SW-MSA (Shifted Window Multi-Head Self-Attention)：通过循环移位操作改变窗口划分方式，使得相邻窗口中的 patch 能够进行信息交互，有效消除窗口边界带来的信息割裂问题。

Patch Merging：在相邻 Stage 之间进行特征降采样，通过拼接相邻 patch 并进行线性投影，将特征维度翻倍同时空间分辨率减半。编码器各 Stage 的特征维度与空间分辨率如表 3 所示。

表 3. Swin-UNETR v2 编码器各 Stage 特征维度与空间分辨率

Stage	特征维度	空间分辨率	Patch 大小
输入	$1 \times 256 \times 256$	256×256	1×1
Stage 1	$48 \times 128 \times 128$	128×128	4×4
Stage 2	$96 \times 64 \times 64$	64×64	8×8
Stage 3	$192 \times 32 \times 32$	32×32	16×16
Stage 4	$384 \times 16 \times 16$	16×16	32×32

2.2.3 CNN 解码器

解码器采用转置卷积逐步上采样特征图，并通过跳跃连接将编码器 Stage 1-3 的特征与解码器对应层级特征拼接 (Concatenation)。每个解码器层级包含：1. 2×2 转置卷积，步长为 2，将空间分辨率翻倍 2. 与编码器对应层级特征拼接 3. 两个 3×3 卷积层进行特征融合。这种设计确保了高层语义信息与低层细节信息的有效融合，提升分割边界的精确定位能力。

2.2.4 前向传播流程

算法 2 描述了 Swin-UNETR v2 的完整前向传播过程。

Algorithm 2: Swin-UNETR v2 前向传播

Input: 输入图像 $I \in \mathbb{R}^{1 \times H \times W}$

Output: 分割概率图 $\hat{Y} \in \mathbb{R}^{K \times H \times W}$

// Patch Partition 与线性嵌入

1 $x_0 \leftarrow \text{Linear}(\text{PatchPartition}(I, P=4))$; // $x_0 \in \mathbb{R}^{48 \times \frac{H}{4} \times \frac{W}{4}}$

// 编码阶段

2 **for** $s \leftarrow 1$ **to** 4 **do**

3 **for** $b \leftarrow 1$ **to** $N_b^{(s)}$ **do**

4 $x_s \leftarrow \text{SwinBlock}(x_s, \text{mode}=\text{W-MSA})$;

5 $x_s \leftarrow \text{SwinBlock}(x_s, \text{mode}=\text{SW-MSA})$;

6 $f_s \leftarrow x_s$; // 保存跳跃连接特征

7 **if** $s < 4$ **then**

8 $x_{s+1} \leftarrow \text{PatchMerging}(x_s)$; // 空间分辨率减半, 通道数翻倍

// 解码阶段

9 $d_4 \leftarrow x_4$; // 瓶颈特征

10 **for** $s \leftarrow 3$ **to** 1 **do**

11 $d_s \leftarrow \text{ConvTranspose}_{2 \times 2}(d_{s+1})$; // 上采样

12 $d_s \leftarrow \text{Concat}(f_s, d_s)$; // 跳跃连接拼接

13 $d_s \leftarrow \text{ConvBlock}(d_s)$; // 特征融合

14 $\hat{Y} \leftarrow \text{Sigmoid}(\text{Conv}_{1 \times 1}(d_1))$; // 输出分割概率

2.2.5 窗口自注意力计算

算法 3 详细描述了 W-MSA 与 SW-MSA 的计算过程。

Algorithm 3: 窗口多头自注意力 (W-MSA / SW-MSA)

Input: 输入特征 $\mathbf{x} \in \mathbb{R}^{C \times H' \times W'}$, 窗口大小 M , 模式 $\text{mode} \in \{\text{W-MSA}, \text{SW-MSA}\}$, 注意力头数 h

Output: 输出特征 $\mathbf{z} \in \mathbb{R}^{C \times H' \times W'}$

```

1  $\mathbf{z}^{(0)} \leftarrow \text{LN}(\mathbf{x});$ 
2 if  $\text{mode} = \text{SW-MSA}$  then
3    $\mathbf{z}^{(0)} \leftarrow \text{CyclicShift}(\mathbf{z}^{(0)}, \lfloor M/2 \rfloor);$  // 循环移位
4 else
5    $\mathbf{z}^{(0)} \leftarrow \mathbf{z}^{(0)};$  // 无移位
6 将  $\mathbf{z}^{(0)}$  划分为  $\frac{H'W'}{M^2}$  个  $M \times M$  窗口  $\{\mathbf{w}_k\}$ ;
7 for 每个窗口  $\mathbf{w}_k$  do
8    $\mathbf{Q}_k, \mathbf{K}_k, \mathbf{V}_k \leftarrow \text{Linear}(\mathbf{w}_k);$  // 线性投影, 各  $C/h$  维
9    $\mathbf{A}_k \leftarrow \text{Softmax}\left(\frac{\mathbf{Q}_k \mathbf{K}_k^\top}{\sqrt{C/h}} + \mathbf{B}\right);$  //  $\mathbf{B}$  为相对位置偏置
10   $\mathbf{w}'_k \leftarrow \mathbf{A}_k \mathbf{V}_k;$  // 注意力加权求和
11  $\mathbf{z}^{(1)} \leftarrow \text{MergeWindows}(\{\mathbf{w}'_k\});$ 
12 if  $\text{mode} = \text{SW-MSA}$  then
13    $\mathbf{z}^{(1)} \leftarrow \text{CyclicShift}(\mathbf{z}^{(1)}, -\lfloor M/2 \rfloor);$  // 反向循环移位
14 else
15    $\mathbf{z}^{(1)} \leftarrow \mathbf{z}^{(1)};$ 
16  $\mathbf{z} \leftarrow \text{MLP}(\text{LN}(\mathbf{z}^{(1)})) + \mathbf{z}^{(1)};$  // 残差连接 + MLP

```

其中相对位置偏置 $\mathbf{B} \in \mathbb{R}^{M^2 \times M^2}$ 通过可学习参数索引获取, 为每个注意力头提供独立的位置编码。SW-MSA 通过循环移位使窗口边界处的 patch 能够与相邻窗口交互, 有效扩大了感受野。

2.2.6 网络配置

表 4 列出了本研究所使用的网络参数配置。

表 4. Swin-UNETR v2 网络配置

参数	值
输入通道数	1 (灰度 CT)
输出通道数	3 (肺、心脏、气管)
特征维度	48
空间维度	2D
梯度检查点	启用 (节省显存)
架构版本	v2
窗口大小	7×7
注意力头数	{3, 6, 12, 24} (各 Stage)

2.3 基于 UNet++ 的对比模型

为系统评估不同架构在胸部 CT 多器官分割任务上的性能差异,本研究引入 UNet++ [9] 作为对比模型。UNet++ 采用嵌套的 U-Net 架构,其核心结构如图 3所示。通过密集的跳跃连接路径, UNet++ 能够有效弥合编码器与解码器之间的语义鸿沟。




图 3. UNet++ 架构示意图。图中 $X_{i,j}$ 表示第 i 层第 j 个卷积块。虚线表示跳跃连接, 实线表示降采样/上采样路径。UNet++ 通过在编码器与解码器之间引入密集卷积块 (橙色节点), 逐步缩小语义差距。

2.3.1 架构设计原理

UNet++ 的核心创新在于其嵌套跳跃连接设计。传统 U-Net 的跳跃连接直接连接编码器第 i 层与解码器第 i 层, 而 UNet++ 在这两层之间引入了额外的卷积块, 形成渐进式特征融合路径。具体来说, 对于第 i 层第 j 个特征图 $X_{i,j}$, 其计算方式为:

$$X_{i,j} = \begin{cases} \text{Conv}(X_{i-1,j}), & j = 0 \\ \text{Conv}(\text{Concat}(X_{i,j-1}, \text{Upsample}(X_{i+1,j-1}), X_{i-1,j})), & j > 0 \end{cases} \quad (6)$$

其中 Conv 表示卷积操作, Concat 表示特征拼接, Upsample 表示上采样操作。

2.3.2 EfficientNet-B2 编码器

UNet++ 的编码器采用 EfficientNet-B2 [7] 作为骨干网络, 并加载 ImageNet 预训练权重。EfficientNet 通过复合缩放策略统一调整网络深度、宽度和输入分辨率:

$$\text{深度} = \alpha^\phi \quad (7)$$

$$\text{宽度} = \beta^\phi \quad (8)$$

$$\text{分辨率} = \gamma^\phi \quad (9)$$

其中 $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$, ϕ 为缩放系数。B2 变体 ($\phi = 1.1$) 在精度与计算量之间取得了良好的平衡。

相较于 Swin-UNETR v2 从头训练的 Swin Transformer 编码器, 预训练的 EfficientNet-B2 编码器具有两方面优势: 一方面, ImageNet 预训练提供了丰富的低层与中层视觉特征先验, 有助于加速收敛并提升特征质量; 另一方面, 卷积架构的局部归纳偏置更适合医学图像中纹理与边界特征的提取。

2.3.3 嵌套跳跃路径解码器

UNet++ 的解码器采用嵌套跳跃连接 (Nested Skip Pathways) 设计, 具有以下特点:

渐进式特征融合: 通过在跳跃连接路径上添加卷积块, 逐步将编码器的高层语义特征与解码器的低层细节特征融合, 避免直接拼接带来的语义鸿沟。该设计受 DenseNet [10] 密集连接思想的启发, 通过特征重用提升信息流动效率。

密集连接模式: 每个特征图 $X_{i,j}$ 不仅连接到 $X_{i,j-1}$ 和 $X_{i-1,j}$, 还通过上采样连接到 $X_{i+1,j-1}$, 形成密集的特征交互网络。

深度监督: UNet++ 在多个层级输出分割结果, 通过深度监督 (Deep Supervision) [11] 策略联合优化, 提升梯度流动和训练稳定性。

2.3.4 前向传播流程

算法 4 描述了 UNet++ 的前向传播过程, 重点展示嵌套跳跃路径的计算逻辑。

Algorithm 4: UNet++ 前向传播

Input: 输入图像 $\mathbf{I} \in \mathbb{R}^{1 \times H \times W}$
Output: 分割概率图 $\hat{\mathbf{Y}} \in \mathbb{R}^{K \times H \times W}$
// 编码器前向传播

```

1 for  $i \leftarrow 0$  to  $L$  do
2    $X_{i,0} \leftarrow \text{EncBlock}_i(\mathbf{I})$  ; // EfficientNet-B2 编码器各阶段特征
// 嵌套跳跃路径
3 for  $j \leftarrow 1$  to  $L$  do
4   for  $i \leftarrow L - j$  to 0 step -1 do
5      $\mathbf{u} \leftarrow \text{Upsample}(X_{i+1,j-1})$  ; // 上采样深层特征
6      $\mathbf{c} \leftarrow \text{Concat}(X_{i,j-1}, \mathbf{u}, X_{i-1,j})$  ; // 密集拼接
7      $X_{i,j} \leftarrow \text{ConvBlock}(\mathbf{c})$  ; // 卷积融合
// 深度监督 (训练时)
8 if training then
9   for  $i \leftarrow 0$  to  $L - 1$  do
10     $\hat{\mathbf{Y}}_i \leftarrow \text{Sigmoid}(\text{Conv}_{1 \times 1}(X_{0,i}))$  ; // 各层输出
11     $\mathcal{L} \leftarrow \sum_{i=0}^{L-1} w_i \cdot \text{Loss}(\hat{\mathbf{Y}}_i, \mathbf{Y})$  ; // 加权损失
12  $\hat{\mathbf{Y}} \leftarrow \text{Sigmoid}(\text{Conv}_{1 \times 1}(X_{0,L}))$  ; // 最终输出

```

其中 $L = 4$ 为网络深度, w_i 为各层损失的权重系数。深度监督策略在训练时同时优化多个层级的输出, 使梯度能够更有效地回传至浅层网络, 缓解深层网络的梯度消失问题。推理时仅使用最终输出 $X_{0,L}$ 。

2.3.5 网络配置

表 5列出了 UNet++ 的网络参数配置。

表 5. UNet++ 网络配置

参数	值
编码器	EfficientNet-B2
编码器权重	ImageNet 预训练
输入通道数	1 (灰度 CT)
输出通道数	3 (肺、心脏、气管)
激活函数	None (DiceFocalLoss 内置 Sigmoid)
深度监督	启用
嵌套深度	4

2.3.6 与 U-Net 的关键差异

表 6对比了标准 U-Net 与 UNet++ 的核心差异：

表 6. U-Net 与 UNet++ 核心差异对比

特性	U-Net
跳跃连接方式	直接连接编码器与解码器
语义差距处理	无，直接拼接
特征融合深度	单层
深度监督	无
网络复杂度	较低
特性	UNet++
跳跃连接方式	嵌套跳跃路径
语义差距处理	渐进式融合
特征融合深度	多层密集连接
深度监督	启用
网络复杂度	较高

2.4 架构对比

表 7对参考基线与两种架构的核心设计差异进行了系统对比。

表 7. 参考基线、Swin-UNETR v2 与 UNet++ 架构对比

特性	参考基线 (U-Net)	Swin-UNETR v2	UNet++ (EfficientNet-B2)
编码器类型	EfficientNet-B2 (CNN)	Swin Transformer	EfficientNet-B2 (CNN)
编码器预训练	ImageNet 预训练	无（从头训练）	ImageNet 预训练
解码器类型	CNN + 跳跃连接	CNN + 跳跃连接	嵌套跳跃路径
特征提取范式	局部卷积 + 复合缩放	全局自注意力	局部卷积 + 复合缩放
归纳偏置	强（卷积局部性先验）	弱（需数据驱动学习）	强（卷积局部性先验）
输出激活	Sigmoid	内置于损失函数	内置于损失函数

三种架构的核心差异在于编码器的设计哲学：参考基线与 UNet++ 均采用预训练的 EfficientNet-B2 编码器，卷积架构的局部归纳偏置与 ImageNet 预训练权重为其提供了良好的特征初始化；Swin-UNETR v2 采用 Swin Transformer 编码器，通过移位窗口自注意力机制捕获全局上下文信息，但缺乏局部归纳偏置，需要更多训练数据与更长训练周期来学习视觉特征。参考基线与 UNet++ 的关键差异在于解码器设计：参考基线采用标准 U-Net 的直接跳跃连接，而 UNet++ 采用嵌套跳跃路径，逐步缩小编码器与解码器特征之间的语义差距，理论上应有利于边界分割精度的提升。值得注意的是，硬预处理基线的结果 (mDice=0.9031) 表明，在相同预处理条件下，标准 U-Net 的性能显著低于 Swin-UNETR v2 和 UNet++，进一步验证了架构改进的必要性。

2.5 数据预处理

数据预处理流程基于 MONAI 框架 [12] 构建 (参考基线基于 albumentations 框架), 训练时与推理时的变换组合如表 8 所示。由于三种架构的特性差异, 参考基线、Swin-UNETR v2 与 UNet++ 采用了不同强度的数据增强策略。

表 8. 数据预处理与数据增强流程

变换方法	参数	参考基线	Swin-UNETR 训练	UNet++ 训练	推理
LoadImaged	keys={image, label}	—	✓	✓	✓
EnsureChannelFirstd	keys={image, label}	—	✓	✓	✓
ScaleIntensityd	keys={image}	—	✓	✓	✓
VerticalFlip	p=0.5	✓	—	—	—
Normalize	ImageNet mean/std	✓	—	—	—
RandFlipd	prob=0.5, axis={0,1}	—	✓	✓	—
RandAffined	rotate, translate, scale	—	✓	✓	—
RandRotate90d	prob=0.5	—	✓	—	—
RandGaussianNoised	prob=0.15, std=0.02	—	✓	—	—
RandAdjustContrastd	prob=0.15, $\gamma \in [0.8, 1.2]$	—	✓	—	—
Resized	256×256, bilinear/nearest	✓	✓	✓	✓
ToTensord	keys={image, label}	—	✓	✓	✓

参考基线采用最轻量的数据增强策略, 仅使用 VerticalFlip (p=0.5) 与 ImageNet 归一化, 这与其预训练编码器的美好特征初始化相匹配。

Swin-UNETR v2 采用了更重的数据增强策略, 包含两类变换: 一方面是**空间变换**(RandFlipd、RandAffined、RandRotate90d), 通过几何变换增强模型对器官位置与形态变化的鲁棒性; 另一方面是**强度变换**(RandGaussianNoised、RandAdjustContrastd), 通过模拟噪声与对比度差异增强模型对不同扫描条件的适应性。较重的数据增强旨在弥补 Transformer 编码器缺乏局部归纳偏置的不足, 通过增加训练样本的多样性来提升模型的泛化能力。

UNet++ 采用了更轻量的数据增强策略, 仅保留 RandFlipd 与 RandAffined (概率降至 0.3, 变换范围缩小), 去除了 RandRotate90d、RandGaussianNoised 和 RandAdjustContrastd。这一设计基于以下考量: 首先, EfficientNet-B2 的 ImageNet 预训练权重已提供良好的特征初始化, 无需通过强数据增强来弥补归纳偏置的不足; 其次, 更轻量的数据增强有助于模型更快地学习训练数据的分布特征, 加速收敛; 此外, 较大的批大小 (64) 本身提供了更稳定的梯度估计, 部分替代了数据增强的正则化效果。

输入图像统一缩放至 256×256, 以满足 Swin Transformer 对输入尺寸为 32 倍数的要求, 同时与 EfficientNet-B2 的输入分辨率保持一致。

2.6 损失函数

本研究采用 DiceFocalLoss 作为训练损失函数,该函数为 Dice Loss [13] 与 Focal Loss [14] 的加权组合:

$$\mathcal{L} = \lambda_{\text{Dice}} \cdot \mathcal{L}_{\text{Dice}} + \lambda_{\text{Focal}} \cdot \mathcal{L}_{\text{Focal}} \quad (10)$$

其中, Dice Loss 定义为:

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_i (p_i \cdot g_i) + \epsilon}{\sum_i p_i + \sum_i g_i + \epsilon} \quad (11)$$

Focal Loss 定义为:

$$\mathcal{L}_{\text{Focal}} = -\alpha_t (1 - p_t)^\gamma \log(p_t) \quad (12)$$

式中 p_i 和 g_i 分别为预测概率与真实标签像素值, ϵ 为平滑因子, α_t 为类别权重, γ 为聚焦参数。

Dice Loss 直接优化分割重叠度, 对类别不平衡具有天然鲁棒性; Focal Loss 通过降低易分类样本的损失权重, 使模型聚焦于难分类区域, 尤其是器官边界与小器官。MONAI 框架中 DiceFocalLoss 默认设置 $\lambda_{\text{Dice}} = \lambda_{\text{Focal}} = 1.0$, $\gamma = 2.0$, 并启用 Sigmoid 激活与背景通道包含。

2.6.1 损失函数计算流程

算法 5 描述了 DiceFocalLoss 的完整计算过程。

Algorithm 5: DiceFocalLoss 计算

Input: 模型输出 $\hat{Y} \in \mathbb{R}^{K \times H \times W}$, 真实标签 $Y \in \{0, 1\}^{K \times H \times W}$, 权重 $\lambda_{\text{Dice}}, \lambda_{\text{Focal}}$, 聚焦参数 γ

Output: 标量损失值 $\mathcal{L}$

```

// Sigmoid 激活
1  $p \leftarrow \text{Sigmoid}(\hat{Y})$ ; // 预测概率
2  $p \leftarrow \text{Clip}(p, \epsilon, 1 - \epsilon)$ ; // 数值稳定性裁剪
// Dice Loss 计算
3  $\text{TP} \leftarrow \sum_i p_i \cdot Y_i$ ; // 逐通道真阳性
4  $\text{FP} \leftarrow \sum_i p_i \cdot (1 - Y_i)$ ; // 逐通道假阳性
5  $\text{FN} \leftarrow \sum_i (1 - p_i) \cdot Y_i$ ; // 逐通道假阴性
6  $\mathcal{L}_{\text{Dice}} \leftarrow 1 - \frac{2 \cdot \text{TP} + \epsilon}{2 \cdot \text{TP} + \text{FP} + \text{FN} + \epsilon}$ ; // 逐通道 Dice Loss
7  $\mathcal{L}_{\text{Dice}} \leftarrow \text{Mean}_c(\mathcal{L}_{\text{Dice}})$ ; // 通道平均
// Focal Loss 计算
8  $p_t \leftarrow Y \cdot p + (1 - Y) \cdot (1 - p)$ ; // 正确分类概率
9  $\alpha_t \leftarrow Y \cdot \alpha + (1 - Y) \cdot (1 - \alpha)$ ; // 类别权重
10  $\mathcal{L}_{\text{Focal}} \leftarrow -\alpha_t \cdot (1 - p_t)^\gamma \cdot \log(p_t)$ ; // 逐像素 Focal Loss
11  $\mathcal{L}_{\text{Focal}} \leftarrow \text{Mean}(\mathcal{L}_{\text{Focal}})$ ; // 全局平均
// 加权组合
12  $\mathcal{L} \leftarrow \lambda_{\text{Dice}} \cdot \mathcal{L}_{\text{Dice}} + \lambda_{\text{Focal}} \cdot \mathcal{L}_{\text{Focal}}$ ;

```

DiceFocalLoss 的设计动机在于: Dice Loss 通过直接优化重叠度指标, 对前景与背景比例悬殊的类别——以气管为典型——具有天然的鲁棒性; Focal Loss 通过调制因子 $(1 - p_t)^\gamma$ 降低易分类样本的损失贡献, 使模型在训练过程中聚焦于难分类区域。两者的组合实现了分割质量与训练稳定性的平衡。

2.7 优化与训练

模型训练采用 AdamW 优化器 [15], 其将权重衰减与梯度更新解耦, 相比标准 Adam [16] 具有更优的正则化效果。学习率调度采用余弦退火策略 (Cosine Annealing) [17]:

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \frac{t\pi}{T_{\max}} \right) \quad (13)$$

其中 $\eta_{\max} = 1 \times 10^{-4}$, $\eta_{\min} = 1 \times 10^{-6}$ 。Swin-UNETR v2 设置 $T_{\max} = 200$, UNet++ 设置 $T_{\max} = 150$ 。该策略在训练初期以较大学习率快速收敛, 后期以极小学习率精细调整, 有效缓解 Transformer 架构对学习率敏感导致的训练震荡问题。完整训练流程如算法 6 所示。

Algorithm 6: 统一训练流程**Hyperparameters:** Epochs T , batch size B , seed $s=520$, model type M **Input:** Dataset $\mathcal{D}$ **Output:** Trained model parameters θ^*

```

1  设置随机种子  $s$ ;
2  if  $M = \text{Swin-UNETR v2}$  then
3      初始化模型  $\theta$  (随机),  $T \leftarrow 200$ ,  $B \leftarrow 16$ ;
4      配置重数据增强 (含 RandRotate90d、RandGaussianNoised 等);
5  else
6      初始化模型  $\theta$  (EfficientNet-B2 加载 ImageNet 预训练权重),  $T \leftarrow 150$ ,  $B \leftarrow 64$ ;
7      配置轻数据增强 (仅 RandFlipd、RandAffined);
8  初始化 AdamW 优化器、CosineAnnealingLR 调度器;
9  for  $t \leftarrow 1$  to  $T$  do
10     从  $\mathcal{D}$  中采样 mini-batch  $\{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^B$ ;
11     预处理:  $\mathbf{y}_i \leftarrow \mathbf{y}_i[:, [2, 1, 0], :, :]$ ; // BGR  $\rightarrow$  RGB
12     前向传播:  $\hat{\mathbf{y}}_i \leftarrow f_{\theta}(\mathbf{x}_i)$ ;
13     计算损失:  $\mathcal{L} = \text{DiceFocalLoss}(\hat{\mathbf{y}}_i, \mathbf{y}_i)$ ;
14     反向传播:  $\theta \leftarrow \theta - \eta_t \cdot \nabla_{\theta} \mathcal{L}$ ;
15     更新学习率: 通过 CosineAnnealingLR 更新  $\eta_t$ ;
16     if  $t \bmod 10 = 0$  then
17         保存 checkpoint:  $f_{\theta}^{(t)}$ ;

```

3 实验设置

3.1 数据集

本研究使用 Kaggle 平台公开的 Chest CT Segmentation 数据集¹, 包含胸部 CT 横断面图像及对应的三器官分割掩码。数据集统计信息如表 9 所示。

¹<https://www.kaggle.com/datasets/polomarco/chest-ct-segmentation>

表 9. 数据集统计信息

项	描述
图像-掩码对总数	1,000
训练集	800 (80 %)
验证集	200 (20 %)
图像格式	JPG, 512×512
掩码格式	JPG (RGB) , 阈值 ≥ 240
分割类别	肺 (R 通道)、心脏 (G 通道)、气管 (B 通道)
配对关系	train.csv: ImageId $\leftrightarrow$ MaskId

掩码为 RGB 三通道图像，像素值 ≥ 240 的区域为有效分割区域。原始数据集通道顺序为 BGR (OpenCV 格式)，训练与测试代码中通过通道交换操作 `labels[:, [2,1,0], :, :]` 将其转换为 RGB 顺序，对应 [肺、心脏、气管]。

3.2 环境配置

本实验的硬件与软件环境如表 10所示。

表 10. 实验环境配置

类别	配置
操作系统	Linux
GPU	NVIDIA A100
PyTorch	≥ 2.0
MONAI	$\geq 1.5.2$
其他依赖	Pandas, NumPy, scikit-learn, Matplotlib, tqdm

3.2.1 训练配置

表 11汇总了各实验的完整训练配置。

表 11. 训练配置对比

超参数	简单预处理基线	硬预处理基线	Swin-UNETR v2	UNet++	Swin-UNETR v2 (扩展)
架构	U-Net (EfficientNet-B2)	U-Net (EfficientNet-B2)	Swin-UNETR v2	UNet++ (EfficientNet-B2)	Swin-UNETR v2
编码器预训练	ImageNet	ImageNet	无 (从头训练)	ImageNet	无 (从头训练)
优化器	Adam	AdamW [15]	AdamW [15]	AdamW [15]	AdamW [15]
学习率	8×10^{-5}	1×10^{-4}	1×10^{-4}	1×10^{-4}	1×10^{-4}
权重衰减	—	1×10^{-5}	1×10^{-5}	1×10^{-5}	1×10^{-5}
学习率调度	ReduceLROnPlateau	CosineAnnealingLR	CosineAnnealingLR	CosineAnnealingLR	CosineAnnealingLR
$T_{\max}$ / patience	patience=3	$T_{\max} = 200$	$T_{\max} = 200$	$T_{\max} = 150$	$T_{\max} = 500$
$\eta_{\min}$	—	10^{-6}	10^{-6}	10^{-6}	10^{-6}
损失函数	BCEDiceLoss	DiceFocalLoss	DiceFocalLoss	DiceFocalLoss	DiceFocalLoss
批大小	8	8	16	64	16
训练轮数	100	1	200	150	500
数据划分	random_state=69	random_state=520	random_state=520	random_state=520	random_state=520
随机种子	555	520	520	520	520
数据增强	轻增强 (仅翻转 + 归一化)	MONAI transforms	重增强 (含旋转 90°、噪声、对比度)	轻增强 (仅翻转、仿射)	重增强 (含旋转 90°、噪声、对比度)
框架	albumentations	MONAI	MONAI	MONAI	MONAI

简单预处理基线与本研究实验在优化器、损失函数、学习率调度等方面均存在显著差

异。硬预处理基线通过使用与实验方法相同的预处理管线和训练配置，建立了公平对比基准。本研究四组实验共享相同的优化器（AdamW）、损失函数（DiceFocalLoss）和学习率调度策略（CosineAnnealingLR），以确保对比的公平性。关键差异在于批大小与训练轮数：UNet++ 采用批大小 64（Swin-UNETR v2 为 16），训练 150 轮（Swin-UNETR v2 为 200 轮）；扩展训练实验将 Swin-UNETR v2 的训练轮数从 200 延长至 500， $T_{\max}$ 相应调整为 500，以探索 Transformer 架构在更长训练周期下的性能潜力。批大小的选择综合考虑了模型显存占用与梯度估计稳定性，UNet++ 的 EfficientNet-B2 编码器参数效率更高，允许使用更大的批大小。

3.3 实验设计

本研究共设计四组独立实验，以全面评估方法的有效性 with 参数优化的影响。实验配置的确经历以下方法学演进过程：

第一阶段——参考基线：项目初期首先复现了数据集提供方的开源 U-Net 实现(exmaple.py)，该实现采用 U-Net + EfficientNet-B2 编码器，配合 BCEDiceLoss 与 Adam 优化器，在验证集上取得了 $\text{val_dice} \approx 0.974$ 的性能。这一基线为后续实验建立了性能参考。同时，为建立公平对比基准，使用与实验方法相同的 MONAI 预处理管线对 U-Net 进行测试，得到硬预处理基线 ($\text{mDice} = 0.9031$)。

第二阶段——Swin-UNETR v2 初步探索：基于参考基线的性能参考，本研究采用 Swin-UNETR v2 作为主架构进行探索，初始配置为批大小 64、无数据增强，仅训练 10 轮。该初步探索的结果显示性能有限，为后续配置优化提供了方向。

第三阶段——配置优化：基于初步探索的结果，对训练配置进行了系统性优化：首先，引入全面的数据增强策略(RandFlipd、RandAffined、RandGaussianNoised、RandAdjustContrastd、RandRotate90d)，以弥补 Transformer 编码器缺乏局部归纳偏置的不足；其次，将批大小从 64 降至 16，以提升泛化能力；此外，引入 CosineAnnealingLR 余弦退火学习率调度器，缓解训练震荡问题；同时，将 Adam 优化器替换为 AdamW，实现解耦权重衰减正则化；最后，将 BCEDiceLoss 替换为 DiceFocalLoss，通过 Focal 机制增强对难分类样本的学习。该优化配置构成了后续基准实验与参数优化实验的基础。

第四阶段——架构对比：在 Swin-UNETR v2 优化配置的基础上，引入 UNet++(EfficientNet-B2 预训练编码器) 作为对比架构，采用更轻量的数据增强策略和更大的批大小 (64)，充分利用预训练编码器的快速收敛特性。

第五阶段——扩展训练：基于 UNet++ 显著优于 Swin-UNETR v2 (200 轮) 的实验结果，进一步探索 Swin-UNETR v2 在更长训练周期下的性能潜力。将训练轮数从 200 延长至 500， $T_{\max}$ 相应调整为 500，从基准实验第 275 轮的 checkpoint 继续训练，以验证 Transformer 架构是否能在充分训练条件下缩小与 CNN 预训练编码器架构的性能差距。

基于上述方法学演进, 本研究设计了以下四组独立实验:

基于 Swin-UNETR v2 的基准实验: 采用优化后的 Swin-UNETR v2 架构, 训练 200 轮, 批大小 16, 随机种子 520, 完整数据增强与余弦退火调度。该实验旨在建立 Swin-UNETR v2 在胸部 CT 多器官分割任务上的基线性能。

基于 Swin-UNETR v2 的参数优化实验: 采用与基准实验相同的 Swin-UNETR v2 架构与超参数配置, 训练 200 轮, 批大小 16, 随机种子 520。该实验旨在验证批大小从 64 降至 16 这一关键参数优化对模型泛化能力与收敛稳定性的影响。与基准实验相比, 参数优化实验在训练后期表现出更稳定的收敛特性 (mDSC 仅从 0.9390 降至 0.9371, 而基准实验从 0.9388 降至 0.9068), 验证了小批大小对缓解过拟合的有效性。

基于 UNet++ 的对比实验: 采用 UNet++ (EfficientNet-B2 编码器) 架构, 训练 150 轮, 批大小 64, 随机种子 520, 轻量数据增强策略。该实验旨在通过对比不同架构的性能, 评估 CNN 预训练编码器与嵌套跳跃路径设计相对于 Transformer 架构在分割精度上的差异。

基于 Swin-UNETR v2 的扩展训练实验: 采用与基准实验相同的 Swin-UNETR v2 架构与超参数配置, 训练 500 轮 (从基准实验第 275 轮 checkpoint 继续训练), 批大小 16, 随机种子 520, 完整数据增强, $T_{\max} = 500$ 。该实验旨在探索 Transformer 架构在更长训练周期下的性能潜力, 验证 Swin-UNETR v2 是否能在充分训练条件下达到与 UNet++ 相当的性能。

基准实验与参数优化实验构成参数优化验证组, 对比实验构成架构对比组, 扩展训练实验构成训练时长探索组。四组独立实验共享相同的数据集划分 (random_state=520)、损失函数 (DiceFocalLoss) 与优化器 (AdamW) 配置, 确保对比的公平性与结论的可靠性。

3.4 评价指标

本研究采用以下指标评估分割性能:

Dice 相似系数 (Dice Similarity Coefficient, DSC): 衡量预测与真实分割的重叠程度, 取值范围为 $[0, 1]$, 值越大表示分割效果越好:

$$\text{Dice} = \frac{2|A \cap B|}{|A| + |B|} \quad (14)$$

其中 A 为预测分割区域, B 为真实标注区域。

交并比 (Intersection over Union, IoU): 又称 Jaccard 系数, 衡量预测与真实分割的交并比:

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (15)$$

平均 Dice/平均 IoU (mDSC/mIoU): 所有类别 Dice/IoU 的算术平均值, 用于综

合评估多类别分割性能。

4 实验结果与分析

如第 3.3 节所述，本研究共进行四组独立实验：基准实验与参数优化实验采用 Swin-UNETR v2 架构（相同配置，验证参数优化效果），对比实验采用 UNet++ 架构（对比研究），扩展训练实验采用 Swin-UNETR v2 架构（探索训练时长影响）。此外，两种参考基线（简单预处理基线与硬预处理基线）的性能数据为实验结果提供了重要的参照。本节依次展示参考基线结果、各实验的定量结果、训练动态与对比分析。

4.1 定量结果

4.1.1 参考基线结果

表 12 展示了两组参考基线的性能。简单预处理基线基于数据集提供方的开源实现，使用 BCEDiceLoss 与 Adam 优化器，训练 100 轮；硬预处理基线使用与实验方法相同的 MONAI 预处理管线和 DiceFocalLoss。

表 12. 参考基线性能对比

指标	简单预处理基线	硬预处理基线
	U-Net (albumentations 预处理)	U-Net (MONAI 预处理)
DSC _肺	—	0.9391
DSC _{心脏}	—	0.9509
DSC _{气管}	—	0.8194
mDSC	—	0.9031
mIoU	—	0.8835
val_dice	≈0.974	—
val_jaccard	≈0.958	—

需要指出的是，简单预处理基线采用整体 Dice/Jaccard 系数作为评价指标，即对所有像素统一计算而不区分器官类别，而本研究后续实验和硬预处理基线采用逐器官计算 Dice 系数再取平均（mDSC）的评价方式。此外，简单预处理基线使用不同的数据划分（random_state=69）和训练框架（albumentations），因此其结果与本研究实验之间不宜直接进行数值比较，但可作为性能水平的参考。

硬预处理基线（mDice=0.9031）使用与实验方法完全相同的预处理管线和评价方式，可作为公平对比的最终基线。该基线的结果显著低于简单预处理基线，表明 MONAI 预处理管线（尤其是 ScaleIntensityd 替代 ImageNet Normalize）对 U-Net 架构的性能产生了较大影响。所有四组实验的 mDSC 均远高于硬预处理基线（0.9031），验证了实验方法的有效性。

4.1.2 基于 Swin-UNETR v2 的基准实验关键轮次结果

表 13展示了基准实验在关键训练轮次的定量评估结果。

表 13. 基于 Swin-UNETR v2 的基准实验关键训练轮次定量评估结果

轮次	DSC _肺	DSC _{心脏}	DSC _{气管}	mDSC
10	0.8308	0.8785	0.6852	0.7982
20	0.8766	0.9114	0.8306	0.8729
50	0.8895	0.9009	0.8722	0.8876
100	0.9065	0.8978	0.9327	0.9124
140	0.9372	0.8956	0.9436	0.9255
170	0.9612	0.9043	0.9458	0.9371
180	0.9632	0.9132	0.9398	0.9388
200	0.9622	0.8433	0.9148	0.9068

基准实验的最优模型出现在第 180 轮, mDSC 达 0.9388。值得注意的是, 第 200 轮时心脏 DSC 出现显著下降(从 0.9132 降至 0.8433), 导致 mDSC 降至 0.9068, 表明 Swin-UNETR v2 在训练后期存在过拟合风险。

4.1.3 基于 Swin-UNETR v2 的参数优化实验关键轮次结果

表 14展示了参数优化实验在关键训练轮次的定量评估结果, 该实验取得了 Swin-UNETR v2 两组独立实验中的最佳性能。

表 14. 基于 Swin-UNETR v2 的参数优化实验关键训练轮次定量评估结果

轮次	DSC _肺	IoU _肺	DSC _{心脏}	IoU _{心脏}	DSC _{气管}	IoU _{气管}	mDSC	mIoU
10	0.8148	0.7888	0.6385	0.6202	0.5224	0.4873	0.6586	0.6321
20	0.8512	0.8275	0.8094	0.7924	0.6139	0.5822	0.7581	0.7340
50	0.8313	0.8057	0.7383	0.7209	0.8629	0.8331	0.8109	0.7865
100	0.9113	0.8905	0.8351	0.8199	0.9225	0.8959	0.8896	0.8688
150	0.9621	0.9420	0.8936	0.8799	0.9412	0.9183	0.9323	0.9134
170	0.9650	0.9461	0.8958	0.8823	0.9449	0.9231	0.9352	0.9172
180	0.9652	0.9464	0.9018	0.8883	0.9451	0.9234	0.9374	0.9194
190	0.9660	0.9475	0.9054	0.8920	0.9458	0.9243	0.9390	0.9212
200	0.9664	0.9480	0.8995	0.8860	0.9455	0.9242	0.9371	0.9194

参数优化实验的最优模型出现在第 190 轮, mDSC 达 0.9390。与基准实验相比, 参数优化实验在训练后期(第 200 轮)的性能下降幅度较小(mDSC 从 0.9390 降至 0.9371, 仅下降 0.0019), 而基准实验从 0.9388 降至 0.9068(下降 0.0320), 表明批大小从 64 降至 16 这一参数优化有效缓解了训练后期的过拟合问题, 提升了模型的泛化稳定性。

4.1.4 基于 UNet++ 的对比实验关键轮次结果

表 15展示了对比实验在关键训练轮次的定量评估结果。

表 15. 基于 UNet++ 的对比实验关键训练轮次定量评估结果

轮次	DSC _肺	DSC _{心脏}	DSC _{气管}	mDSC
10	0.8846	0.8765	0.7427	0.8346
20	0.9366	0.8694	0.8520	0.8860
50	0.9470	0.9173	0.9008	0.9217
60	0.9568	0.9617	0.9319	0.9501
100	0.9689	0.9701	0.9505	0.9632
120	0.9695	0.9703	0.9544	0.9647
140	0.9703	0.9712	0.9560	0.9658
150	0.9702	0.9718	0.9563	0.9661

对比实验的最优模型出现在第 150 轮（最后一个训练轮次），mDSC 达 0.9661，显著优于 Swin-UNETR v2 的两组独立实验。值得注意的是，UNet++ 仅用 10 轮训练即达到 mDSC 0.8346，已接近 Swin-UNETR v2 训练 50 轮的水平，充分体现了预训练编码器的优势。此外，UNet++ 在训练过程中未出现性能下降现象，模型在整个训练周期内保持稳定提升。

4.1.5 基于 Swin-UNETR v2 的扩展训练实验关键轮次结果

表 16展示了扩展训练实验在关键训练轮次的定量评估结果。该实验从基准实验第 275 轮 checkpoint 继续训练至 500 轮， $T_{\max} = 500$ 。

表 16. 基于 Swin-UNETR v2 的扩展训练实验关键训练轮次定量评估结果

轮次	DSC _肺	IoU _肺	DSC _{心脏}	IoU _{心脏}	DSC _{气管}	IoU _{气管}	mDSC	mIoU
10	0.8188	0.7918	0.6202	0.6015	0.4999	0.4654	0.6463	0.6196
50	0.8232	0.7964	0.7383	0.7208	0.7986	0.7774	0.7867	0.7649
100	0.8859	0.8634	0.8469	0.8309	0.9008	0.872	0.8778	0.8554
150	0.9173	0.8909	0.8161	0.7997	0.8996	0.8697	0.8777	0.8534
200	0.9499	0.9266	0.8551	0.8402	0.9312	0.9045	0.9121	0.8904
250	0.9646	0.9449	0.9491	0.9344	0.9391	0.9149	0.9509	0.9314
300	0.9634	0.9436	0.9609	0.9473	0.9455	0.9227	0.9566	0.9379
350	0.9664	0.9474	0.9633	0.9498	0.9486	0.9273	0.9594	0.9415
400	0.9694	0.9516	0.9677	0.9546	0.9524	0.9322	0.9632	0.9461
430	0.9711	0.9539	0.9681	0.9554	0.9551	0.9355	0.9648	0.9483
450	0.9714	0.9543	0.9685	0.956	0.9563	0.9367	0.9654	0.949
480	0.9719	0.9548	0.9687	0.9561	0.9559	0.9365	0.9655	0.9491
500	0.9718	0.9547	0.9682	0.9556	0.9564	0.937	0.9655	0.9491

扩展训练实验的最优模型出现在第 480 轮，mDSC 达 0.9655，与 UNet++ 的 0.9661 仅差 0.0006。与 200 轮训练的 Swin-UNETR v2 最佳结果（mDSC=0.9390）相比，扩展训练

带来了 2.65 个百分点的显著提升。特别值得注意的是，心脏 DSC 从 200 轮训练的 0.9054 大幅提升至 0.9687（提升 6.33 个百分点），表明 Transformer 架构在充分训练条件下能够有效学习心脏等边界模糊器官的分割特征。此外，扩展训练实验在训练后期（第 480-500 轮）性能保持稳定（mDSC 维持在 0.9655），未出现 200 轮训练中观察到的性能下降现象，说明更长的训练周期配合 $T_{\max} = 500$ 的余弦退火调度有助于模型收敛至更优的参数空间。

4.1.6 最佳性能对比

表 17 汇总了参考基线与四组独立实验的最佳性能结果。

表 17. 参考基线与四组独立实验最佳性能对比

指标	硬预处理基线 U-Net (MONAI)	基准实验 Swin-UNETR v2	参数优化实验 Swin-UNETR v2	对比实验 UNet++	扩展训练实验 Swin-UNETR v2	整体最佳
DSC _肺	0.9391	0.9632	0.9660	0.9702	0.9719	0.9719
DSC _{心脏}	0.9509	0.9132	0.9054	0.9718	0.9687	0.9718
DSC _{气管}	0.8194	0.9398	0.9458	0.9563	0.9559	0.9563
mDSC	0.9031	0.9388	0.9390	0.9661	0.9655	0.9661
mIoU	0.8835	—	0.9212	—	0.9491	0.9491
最佳轮次	1	180	190	150	480	-

注：硬预处理基线使用与实验方法相同的 MONAI 预处理管线和评价方式，可作为公平对比基准。简单预处理基线的整体 $\text{val_dice} \approx 0.974$ ，但因评价方式不同未列入此表。部分实验的 mIoU 数据以“—”标注表示未记录。

从表中可以得出以下关键发现：首先，UNet++ 取得了最高的 mDSC (0.9661)，扩展训练的 Swin-UNETR v2 紧随其后 (0.9655)，两者仅差 0.0006，表明 Transformer 架构在充分训练条件下可达到与 CNN 预训练编码器架构相当的性能；其次，扩展训练实验在肺部 DSC 上取得了所有实验的最高值 (0.9719)，甚至超过了 UNet++ (0.9702)；此外，心脏分割方面，UNet++ (0.9718) 仍略优于扩展训练的 Swin-UNETR v2 (0.9687)，但差距已从 200 轮训练时的 5.86pp 缩小至 0.31pp；同时，所有四组实验的 mDSC 均显著高于硬预处理基线 (0.9031)，验证了实验方法的有效性；最后，基准实验与参数优化实验的 Swin-UNETR v2 结果非常接近 (mDSC 差异仅 0.0002)，但参数优化实验在训练后期稳定性显著更优，验证了批大小优化对缓解过拟合的有效性。

4.2 训练动态

4.2.1 损失收敛分析

图 4 展示了四组独立实验的训练损失变化趋势。




图 4. 四组独立实验的训练损失曲线。(a)(b) Swin-UNETR v2 呈现两阶段收敛特征, 损失从 ~ 0.9 降至 ~ 0.30 ; (c) UNet++ 在第 50-60 轮间出现急剧下降 (从 0.55 降至 0.07), 最终收敛至 0.034; (d) 扩展训练实验从第 276 轮继续训练, 损失从 0.053 缓慢收敛至 0.036, 表明模型在更长训练周期下持续优化。

四组独立实验的损失曲线呈现出截然不同的收敛特征：

Swin-UNETR v2 基准与参数优化实验：损失曲线呈现两阶段收敛特征。第一阶段（第 1-125 轮）损失快速下降，从初始的 ~ 0.9 降至 ~ 0.38 ；第二阶段（第 126-200 轮）损失在较低水平缓慢收敛，最终稳定在 0.30 左右。基准实验在第 162 轮附近出现一次显著的损失跳变（从 0.38 降至 0.32），可能归因于余弦退火调度器在训练中期学习率仍较大时，模型参数跨越损失曲面鞍点所致。

UNet++ 对比实验：损失曲线呈现出更为独特的三阶段收敛特征。第一阶段（第 1-50 轮）损失缓慢下降，从 0.96 降至 0.55，与 Swin-UNETR v2 的收敛速度相近；第二阶段（第 51-60 轮）损失急剧下降，从 0.44 骤降至 0.07，这一突变可能与预训练编码器的特征激活有关——当学习率降至特定阈值时，预训练特征与任务特定特征实现有效对齐，导致损失骤降；第三阶段（第 60-150 轮）损失在极低水平缓慢收敛，最终稳定在 0.034 左右，远低于 Swin-UNETR v2 的 0.30，表明 UNet++ 在训练集上实现了更充分的拟合。

Swin-UNETR v2 扩展训练实验：损失数据从第 276 轮开始（从基准实验第 275 轮 checkpoint 继续训练），初始损失为 0.0526，远低于 200 轮训练结束时的 0.30，表明模型在 200 轮训练后仍处于持续优化阶段。随着训练继续，损失从 0.0526 缓慢下降至 0.0359（第 500 轮），下降幅度约 31.6%。这一结果说明 Swin-UNETR v2 在 200 轮训练后并未充分收敛，延长训练周期可使模型进一步优化，最终达到与 UNet++ 相近的损失水平。

4.2.2 各器官 Dice 系数变化趋势

图 5 展示了四组独立实验中各器官 Dice 系数随训练轮次的变化趋势。




图 5. 四组独立实验各器官 Dice 系数变化趋势。(a)(b) Swin-UNETR v2 中肺收敛最快，心脏与气管后期波动明显；(c) UNet++ 中三类器官均在第 60 轮后快速收敛至 0.95 以上；(d) 扩展训练实验中，心脏 DSC 在第 200-300 轮间出现显著跃升（从 0.86 至 0.96），最终三类器官 DSC 均达到 0.95 以上。

从图中可以观察到以下规律：

Swin-UNETR v2 基准与参数优化实验：肺 DSC 在训练早期即快速上升至 0.90 以上，后期稳定在 0.96 附近；心脏 DSC 上升较为缓慢，在第 130 轮后趋于 0.90，但基准实验在第 200 轮出现显著下降 (0.8433)，表明存在过拟合风险；气管 DSC 在训练初期波动较大，最终稳定在 0.94 左右。

UNet++ 对比实验：三类器官的 DSC 均在第 60 轮后快速上升至 0.95 以上，展现出极为高效的收敛特性。特别值得注意的是，心脏 DSC 在第 60 轮出现跳变（从 0.9173 升至 0.9617），与损失曲线的骤降点吻合，此后持续稳定提升至 0.9718。UNet++ 中心脏 DSC 甚至超过了肺 DSC，这在 Swin-UNETR v2 的 200 轮实验中从未观察到，表明预训练编码器对心脏分割的提升尤为显著。

Swin-UNETR v2 扩展训练实验：扩展训练实验的 Dice 曲线呈现出与 200 轮训练截然不同的特征。最显著的变化出现在心脏 DSC：在第 200-300 轮间，心脏 DSC 从 0.8551 跃升至 0.9609，提升超过 10 个百分点，这一跃升与损失曲线的持续下降相对应。此后心脏 DSC 继续缓慢提升至 0.9687，与 UNet++ 的 0.9718 仅差 0.31 个百分点。肺 DSC 和气管 DSC 也在扩展训练中持续提升，分别达到 0.9719 和 0.9559。这一结果表明，Swin-UNETR v2 在 200 轮训练时远未收敛，Transformer 架构需要更长的训练周期来充分学习器官分割特征，尤其是边界模糊器官（心脏）的特征。

4.2.3 各实验最佳模型性能对比

图 6 以柱状图形式直观对比了四组独立实验最优模型在各器官上的 DSC。




图 6. 四组独立实验最佳模型各器官 DSC 对比。UNet++ 取得最高 mDSC (0.9661)，扩展训练的 Swin-UNETR v2 紧随其后 (0.9655)，两者差距仅 0.0006。扩展训练实验在肺部 DSC 上取得最高值 (0.9719)。

4.3 Swin-UNETR v2 与 UNet++ 对比分析

基于上述实验结果，本节从多个维度对两种架构进行系统对比分析。

4.3.1 分割精度对比

表 18 量化了各实验相对于硬预处理基线的性能提升,以及不同训练策略下 Swin-UNETR v2 的性能变化。

表 18. 各实验相对于硬预处理基线的性能提升

器官	硬预处理基线 U-Net (MONAI)	Swin-UNETR v2 (200 轮最佳)	Swin-UNETR v2 (参数优化)	UNet++ (150 轮)	Swin-UNETR v2 (500 轮扩展)
肺	0.9391	0.9632	0.9660	0.9702	0.9719
心脏	0.9509	0.9132	0.9054	0.9718	0.9687
气管	0.8194	0.9398	0.9458	0.9563	0.9559
mDSC	0.9031	0.9388	0.9390	0.9661	0.9655

从表中可以得出以下关键发现:首先,所有实验方法均显著优于硬预处理基线($mDSC=0.9031$),验证了实验方法的有效性;其次, UNet++ 取得了最高的 $mDSC$ (0.9661), 扩展训练的 Swin-UNETR v2 紧随其后 (0.9655), 两者仅差 0.0006; 此外, 扩展训练实验在肺部 DSC 上取得了所有实验的最高值 (0.9719); 最后, 200 轮训练的 Swin-UNETR v2 在心脏分割上显著低于硬预处理基线 (0.9054 vs 0.9509), 但扩展训练后大幅提升至 0.9687, 表明 Transformer 架构需要更长的训练周期来学习心脏等边界模糊器官的分割特征。

4.3.2 收敛速度对比

两种架构的收敛速度存在显著差异。以 $mDSC$ 达到 0.90 为基准: Swin-UNETR v2 需要约 100 轮训练 (参数优化实验第 100 轮 $mDSC=0.8896$), 而 UNet++ 仅用约 20 轮即达到 $mDSC=0.8860$, 在第 60 轮已达到 $mDSC=0.9501$ 。UNet++ 的收敛速度约为 Swin-UNETR v2 的 5 倍, 这主要归功于预训练编码器提供的良好特征初始化。

此外, UNet++ 的训练过程更为稳定, 未出现 Swin-UNETR v2 中观察到的后期性能下降现象。Swin-UNETR v2 基准实验在第 200 轮出现心脏 DSC 骤降 (0.9132 $\rightarrow$ 0.8433), 而 UNet++ 在整个训练周期内各器官 DSC 均保持单调递增或稳定, 表现出更优的训练稳定性。值得注意的是, 扩展训练实验 (500 轮) 也未出现性能下降现象, 说明更长的训练周期配合 $T_{max} = 500$ 的余弦退火调度有助于模型稳定收敛。


4.3.3 训练效率对比

从训练效率角度, UNet++ 仅需 150 轮训练即达到 $mDSC=0.9661$, 而 Swin-UNETR v2 需要 500 轮训练才达到 $mDSC=0.9655$ 。结合批大小差异 (UNet++ 批大小 64 vs Swin-


UNETR v2 批大小 16), UNet++ 在每个 epoch 中处理更多的样本梯度, 进一步加速了有效收敛。这一结果表明, 在计算资源有限的场景下, 采用预训练编码器的 CNN 架构在训练效率上具有明显优势; 而 Transformer 架构虽然需要更长的训练时间, 但最终能够达到相近的性能水平。

4.4 定性可视化


图 7展示了三种模型在同一测试样本上的分割效果对比。从上到下分别为基线模型 (U-Net)、Swin-UNETR v2 模型和 UNet++ 模型的分割结果, 每个子图包含原始 CT 图像、真实标注和模型预测三部分。



(a) 基线模型 (U-Net)



(b) Swin-UNETR v2 模型



(c) UNet++ 模型

■ 肺 (Lung) ■ 心脏 (Heart) ■ 气管 (Trachea)

图 7. 三种模型的分割可视化结果对比。从上到下依次为: (a) 基线模型 (U-Net), (b) Swin-UNETR v2 模型, (c) UNet++ 模型。每个子图包含原始 CT 图像、真实标注和模型预测三列。红色表示肺部区域, 绿色表示心脏区域, 蓝色表示气管区域。

从可视化结果可以观察到以下差异：

基线模型：在肺部区域的分割较为完整，但心脏区域的边界不够精确，气管区域的分割存在明显缺失 ($Dice=0.4641$)，表明基线模型在小器官和复杂结构的分割上存在局限性。

Swin-UNETR v2 模型：肺部和心脏区域的分割质量显著提升，气管区域的分割连续性明显改善 ($Dice=0.9375$)。模型能够较好地处理器官边界的模糊区域，整体分割精度较高。

UNet++ 模型：在所有器官上均表现出最佳的分割效果，肺部 ($Dice=0.9695$)、心脏 ($Dice=0.7466$) 和气管 ($Dice=0.8696$) 的分割结果与真实标注高度吻合。特别是在心脏与周围组织的边界处，UNet++ 模型能够更精确地定位器官轮廓。

综合来看，UNet++ 模型凭借其嵌套跳跃路径设计和预训练编码器，在复杂医学图像分割任务上展现出明显优势，能够有效捕获不同尺度器官的形态特征，实现高精度的多器官分割。

5 讨论

5.1 Swin-UNETR v2 与 UNet++ 的对比分析

本研究的实验结果揭示了 Swin-UNETR v2 与 UNet++ (EfficientNet-B2 编码器) 在胸部 CT 多器官分割任务上的复杂关系。在 200 轮训练条件下，UNet++ 全面优于 Swin-UNETR v2；然而，扩展训练实验表明，Swin-UNETR v2 在 500 轮训练后可达到与 UNet++ 相当的性能。这一性能差异与收敛可从以下维度进行深入分析：

关于**预训练编码器的关键作用**，Swin-UNETR v2 的 Swin Transformer 编码器从头训练，缺乏先验特征知识，需要通过大量训练数据与训练轮次来学习视觉特征。相比之下，UNet++ 的 EfficientNet-B2 编码器加载了 ImageNet 预训练权重，尽管 ImageNet 与医学 CT 图像的领域差异较大，但预训练权重仍提供了有价值的低层特征——包括边缘与纹理检测——和 中层特征——包括形状组合——，这些特征经微调后可有效地迁移至 CT 分割任务。这一发现与医学图像分割领域的已有研究一致：在有限数据集上，预训练编码器通常优于从头训练的编码器。然而，扩展训练实验的结果表明，这一优势并非不可逾越——通过延长训练周期，从头训练的 Transformer 编码器也能逐步学习到有效的视觉特征，最终达到与预训练编码器相当的性能水平。

关于**归纳偏置的影响**，卷积神经网络的局部归纳偏置（局部连接、权值共享、平移等变性）天然适合图像处理任务，尤其是对局部纹理与边界特征的提取。Swin Transformer 虽然通过移位窗口机制实现了全局建模能力，但其弱归纳偏置意味着模型需要更多数据来学习这些局部特征。在仅 800 张训练图像的有限数据条件下，卷积架构的归纳偏置优势更为突出。但扩展训练实验表明，通过更长的训练周期（500 轮），Transformer 架构可以逐步弥补

归纳偏置的不足，最终在肺部 DSC 上甚至超过了 UNet++ (0.9719 vs 0.9702)。

在**嵌套跳跃路径的语义桥接效应**方面，UNet++ 的嵌套跳跃连接通过逐步缩小编码器与解码器特征之间的语义差距，使传递至解码器的特征更具语义一致性。相比之下，Swin-UNETR v2 采用传统的直接跳跃连接，编码器浅层特征（低级纹理）与解码器深层特征（高级语义）之间的语义鸿沟可能影响分割边界的精确性。

关于**批大小与数据增强的交互效应**，UNet++ 采用批大小 64 (Swin-UNETR v2 为 16)，更大的批大小提供了更稳定的梯度估计，有助于模型在预训练权重的良好初始化附近进行高效优化。同时，UNet++ 采用了更轻量的数据增强策略，避免了过度增强对预训练特征的破坏。这一组合（大批大小 + 轻增强 + 预训练权重）在有限数据集上表现出了优异的效果。

关于**训练时长对 Transformer 架构的关键影响**，这是本研究最重要的发现之一。Swin-UNETR v2 在 200 轮训练时 mDSC 仅为 0.9390，与 UNet++ 的 0.9661 相差 2.71 个百分点；但在 500 轮训练后，mDSC 提升至 0.9655，与 UNet++ 仅差 0.0006。这一结果表明，Transformer 架构的性能瓶颈并非架构本身的固有限制，而是训练不充分所致。特别是心脏 DSC 从 200 轮的 0.9054 大幅提升至 500 轮的 0.9687（提升 6.33 个百分点），说明 Transformer 编码器需要更长的训练周期来学习边界模糊器官的分割特征。

关于**收敛稳定性的差异**，Swin-UNETR v2 在 200 轮训练后期出现了性能下降现象（基准实验第 200 轮心脏 DSC 骤降），表明 Transformer 架构在训练周期与余弦退火调度不匹配时存在过拟合风险。然而，扩展训练实验（500 轮， $T_{\max} = 500$ ）在整个训练过程中保持稳定提升，未出现性能回退，说明合理设置训练周期与余弦退火参数对 Transformer 架构的训练稳定性至关重要。UNet++ 在整个训练过程中保持稳定提升，这得益于预训练权重的正则化效应与更大批大小带来的梯度稳定性。

5.2 与参考基线的对比分析

本研究建立了两种参考基线，为实验结果提供了不同维度的参照：

关于**简单预处理基线**，数据集提供方的开源 U-Net 实现（EfficientNet-B2 编码器 + BCEDiceLoss + albumentations 预处理）在验证集上取得了 $\text{val_dice} \approx 0.974$ 的性能。该基线采用整体 Dice 系数评价，与本研究实验的逐器官 mDSC 评价方式不同，因此不宜直接数值对比。但其高性能水平表明，在简单预处理条件下，U-Net + EfficientNet-B2 已能取得优异的分割效果。

关于**硬预处理基线**，使用与实验方法相同的 MONAI 预处理管线对 U-Net (EfficientNet-B2 编码器) 进行测试，得到 $\text{mDice} = 0.9031$ 。该基线的结果显著低于简单预处理基线，表明 MONAI 预处理管线（尤其是 ScaleIntensityd 替代 ImageNet Normalize）对 U-Net 架构的性能产生了较大影响。硬预处理基线作为公平对比的最终基准，所有四组实验的 mDSC 均

远高于该基线（最低 0.9388 vs 0.9031），验证了实验方法的有效性。

关于**方法论启示**，两种基线的对比揭示了一个重要发现：预处理方式对 U-Net 架构的性能影响显著（ $\text{val_dice} \approx 0.974$ vs $\text{mDice} = 0.9031$ ）。简单预处理基线使用 ImageNet Normalize，与 EfficientNet-B2 的预训练权重匹配良好；而 MONAI 的 ScaleIntensityd 虽然更适用于医学图像，但与预训练权重不匹配，导致性能大幅下降。这表明在评估不同方法的性能时，必须控制预处理方式这一混淆变量，否则可能得出误导性的结论。

5.3 器官分割难度分析

综合四组独立实验的结果，器官分割难度呈现以下规律：

肺：在两种架构中均最易分割，DSC 稳定在 0.96 以上。扩展训练实验的肺部 DSC 达到 0.9719，为所有实验最高值。肺组织在 CT 图像中占比最大（约占图像面积的 30-40%）且对比度高（含气组织与周围软组织灰度差异显著），这些有利条件使得即使较简单的模型也能取得良好的分割效果。

气管：气管像素占比最小（ $<5\%$ ），但得益于 DiceFocalLoss 对难分类样本的聚焦效应，两种架构均取得了较好的分割效果。Swin-UNETR v2（200 轮）的气管 DSC 为 0.9458，扩展训练后提升至 0.9559，UNet++ 为 0.9563，提升幅度相对较小，表明 DiceFocalLoss 已有效缓解了气管的类别不平衡问题。

心脏：心脏是 200 轮训练时两种架构性能差异最大的器官（Swin-UNETR v2 最佳 0.9054 vs UNet++ 0.9718，差距 6.64pp）。然而，扩展训练实验将这一差距大幅缩小（0.9687 vs 0.9718，仅差 0.31pp），表明心脏分割的困难主要源于 Transformer 架构训练不充分，而非架构本身的固有限制。心脏分割困难的原因在于：首先，心脏与周围纵隔组织的灰度差异较小，边界模糊；其次，心脏形态存在较大的个体差异；此外，心脏区域的灰度值与背景较为接近。

5.4 损失函数的有效性

DiceFocalLoss 在两种架构中均展现了良好的效果。Dice 部分直接优化分割重叠度，对类别不平衡具有天然鲁棒性；Focal 部分通过降低易分类样本的损失权重，使模型聚焦于难分类区域，尤其是器官边界与小器官。两者结合有效缓解了类别不平衡问题，使得气管这类小器官的 DSC 能够达到 0.94 以上。

5.5 局限性分析

本研究存在以下局限性。首先，**数据集规模有限**：本实验使用的 Kaggle 数据集仅有 1,000 对图像-掩码对，与医学图像分割领域常用的大规模数据集相比规模较小。更大规模、多中心的数据集将有助于进一步验证两种架构的性能差异，特别是 Swin-UNETR v2 在更

大数据集上是否能够进一步缩小与 UNet++ 的差距。其次,本研究**仅为 2D 分割**:采用的是 2D 分割方法,没有利用 CT 层间的连续性信息。3D 分割方法可能能够利用更多的上下文信息,进一步提升分割精度。此外,在**对比实验的变量控制**方面,对比实验(UNet++)与基准实验、参数优化实验(Swin-UNETR v2)在批大小、训练轮数和数据增强策略上存在差异,这些混淆变量可能影响架构对比的结论。理想的对比实验应仅改变架构本身,控制其他变量不变。然而,不同架构的最优训练配置本身存在差异,完全控制变量可能无法反映各架构的实际潜力。同时,本研究**缺乏更多方法的对比**:仅对比了 Swin-UNETR v2 与 UNet++ 两种架构,未涉及 TransUNet、nnU-Net 等其他前沿方法,无法全面评估本方法在领域内的相对优势。最后,关于**扩展训练实验的延续性**,扩展训练实验从基准实验第 275 轮 checkpoint 继续训练,而非从头训练 500 轮,这可能导致训练动态与完整 500 轮训练存在差异。此外,仅进行了单一随机种子的实验,未评估不同随机种子对扩展训练结果的影响。

5.6 未来工作展望

基于本研究的结果和局限性,未来可以从以下方向进行探索。首先,关于 **Swin-UNETR v2 的预训练策略**,可以探索为 Swin Transformer 编码器引入自监督预训练——以 Masked Image Modeling 为代表——,以弥补其缺乏预训练权重的不足,评估预训练对 Swin-UNETR v2 性能的提升幅度。其次,在 **3D 分割方法**方面,可以将 2D 分割方法扩展为 3D 版本,充分利用 CT 图像的层间信息,探索 3D 上下文对分割性能的提升潜力。此外,关于**混合架构设计**,可以结合 Transformer 的全局建模能力与 CNN 的局部特征提取优势,设计混合编码器架构,如 CNN 提取局部特征后接 Transformer 建模全局依赖。同时,在**模型轻量化与部署**方面,可以通过知识蒸馏、剪枝、量化等技术压缩模型,使其能够在资源受限的环境中部署。最后,关于**跨数据集泛化能力验证**,可以在多个公开数据集上评估本方法的性能,并探索域适应技术,提升模型在不同来源数据上的泛化能力。

6 结论

本研究针对胸部 CT 图像的多器官分割任务,系统比较了 Swin-UNETR v2 与 UNet++ (EfficientNet-B2 编码器)两种架构的性能,并建立了两种参考基线(简单预处理基线与硬预处理基线)。在 Kaggle Chest CT Segmentation 数据集上进行了四组独立实验:基准实验与参数优化实验采用 Swin-UNETR v2 (相同配置,验证参数优化效果),对比实验采用 UNet++ (架构对比),扩展训练实验采用 Swin-UNETR v2 (500 轮,探索训练时长影响)。

实验结果表明:首先, Swin-UNETR v2 的基准实验与参数优化实验最佳 mDSC 分别为 0.9388 与 0.9390,参数优化实验在训练后期表现出更稳定的收敛特性(mDSC 仅下降

0.0019 vs 基准实验下降 0.0320), 验证了批大小优化对缓解过拟合的有效性; 其次, UNet++ 取得了 0.9661 的 mDSC, 显著优于 200 轮训练的 Swin-UNETR v2, 其中肺、心脏、气管的 DSC 分别为 0.9702、0.9718 和 0.9563; 此外, 扩展训练实验表明, 将 Swin-UNETR v2 的训练从 200 轮延长至 500 轮, mDSC 从 0.9390 提升至 0.9655, 与 UNet++ 的 0.9661 仅差 0.0006, 其中肺部 DSC 达到 0.9719 (所有实验最高), 心脏 DSC 从 0.9054 大幅提升至 0.9687; 同时, 硬预处理基线 (mDice=0.9031) 证实所有实验方法均大幅优于公平对比基线; 最后, UNet++ 的收敛速度约为 Swin-UNETR v2 的 5 倍, 且训练过程更为稳定。

本研究最重要的发现是: Transformer 架构在充分训练条件下 (500 轮) 可以达到与 CNN 预训练编码器架构相当的性能, 其性能瓶颈并非架构本身的固有限制, 而是训练不充分所致。这一发现对胸部 CT 分割任务的架构选择具有重要参考意义: 在计算资源充足的场景下, 从头训练的 Transformer 架构可以通过延长训练周期达到与预训练 CNN 架构相近的性能; 在计算资源有限的场景下, 采用预训练编码器的 CNN 架构在训练效率上具有明显优势。此外, 硬预处理基线与简单预处理基线的显著差异 (mDice=0.9031 vs val_dice $\approx$ 0.974) 表明, 预处理方式对模型性能影响显著, 在评估不同方法时必须控制预处理方式这一混淆变量。

本研究的贡献包括: 首先, 系统比较了 Transformer 与 CNN 预训练编码器架构在胸部 CT 分割任务上的性能差异, 并揭示了训练时长对 Transformer 架构性能的关键影响; 其次, 建立了两种参考基线 (简单预处理与硬预处理), 为公平对比提供了基准; 此外, 揭示了预处理方式、预训练策略与归纳偏置对分割性能的交互影响; 最后, 提供了完整的实验流程和结果分析, 为该领域的后续研究提供了可复现的参考。

尽管本研究取得了良好的结果, 但仍存在数据集规模有限、对比实验变量控制不够严格、扩展训练实验的延续性等局限性。未来可以从自监督预训练、3D 分割、混合架构设计、更系统的训练时长研究等方向进一步探索, 提升方法的性能和实用性。

参考文献

- [1] A. Hatamizadeh et al. "Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images". In: *Int. Conf. Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2022, pp. 272–282.
- [2] O. Ronneberger, P. Fischer, and T. Brox. "U-Net: Convolutional Networks for Biomedical Image Segmentation". In: *Int. Conf. Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2015, pp. 234–241.
- [3] F. Isensee et al. "nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation". In: *Nature Methods* 18.2 (2021), pp. 203–211.

- [4] J. Chen et al. “TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation”. In: *arXiv preprint arXiv:2102.04306* (2021).
- [5] H. Wang et al. “UCTransNet: Rethinking the Skip Connections in U-Net from a Channel-wise Perspective with Transformer”. In: *AAAI Conf. Artificial Intelligence*. 2022.
- [6] Z. Liu et al. “Swin Transformer: Hierarchical Vision Transformer using Shifted Windows”. In: *IEEE/CVF Int. Conf. Computer Vision (ICCV)*. 2021, pp. 10012–10022.
- [7] M. Tan and Q. V. Le. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. In: *Int. Conf. Machine Learning (ICML)*. 2019.
- [8] A. Dosovitskiy et al. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *arXiv preprint arXiv:2010.11929* (2021).
- [9] Z. Zhou et al. “UNet++: A Nested U-Net Architecture for Medical Image Segmentation”. In: *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (DLMIA)*. Springer, 2018, pp. 3–11.
- [10] G. Huang et al. “Densely Connected Convolutional Networks”. In: (2017), pp. 2261–2269.
- [11] C.-Y. Lee et al. “Deeply-Supervised Nets”. In: *AISTATS* (2015), pp. 562–570.
- [12] M. J. Cardoso et al. “MONAI: An open-source framework for deep learning in healthcare”. In: *arXiv preprint arXiv:2211.02701* (2022).
- [13] F. Milletari, N. Navab, and S.-A. Ahmadi. “V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation”. In: *Int. Conf. 3D Vision (3DV)*. 2016, pp. 565–571.
- [14] T.-Y. Lin et al. “Focal Loss for Dense Object Detection”. In: *IEEE Int. Conf. Computer Vision (ICCV)*. 2017, pp. 2980–2988.
- [15] I. Loshchilov and F. Hutter. “Decoupled Weight Decay Regularization”. In: *arXiv preprint arXiv:1711.05101* (2017).
- [16] D. P. Kingma and J. L. Ba. “Adam: A Method for Stochastic Optimization”. In: *arXiv preprint arXiv:1412.6980* (2015).
- [17] L. N. Smith. “Cyclical Learning Rates for Training Neural Networks”. In: (2017), pp. 464–472.